

CIS2210CP07

Segmentación Semi-Automática de Tejido
Adiposo en el Espacio Parafaríngeo por Medio
de Aprendizaje Profundo

David Alejandro Castillo Chíquiza

Oscar David Falla Pulido

Juan Sebastián Ruiz Bulla

PONTIFICIA UNIVERSIDAD JAVERIANA
FACULTAD DE INGENIERIA
PROGRAMA DE INGENIERIA DE SISTEMAS
BOGOTÁ, D.C.
2022

CIS2210CP07

Segmentación Semi-Automática de Tejido Adiposo en el Espacio
Parafaríngeo por Medio de Aprendizaje Profundo

Autores:

David Alejandro Castillo Chíquiza
Oscar David Falla Pulido
Juan Sebastián Ruiz Bulla

MEMORIA DE PROYECTO FINAL DE PREGRADO
REALIZADA PARA CUMPLIR UNO DE LOS REQUISITOS
DE LA CARRERA DE INGENIERÍA EN SISTEMAS

Director

Ing. Cesar Julio Bustacara Medina

Jurados del Trabajo Final de Grado

Ing. <Name of the jury >
Ing. < Name of the jury >

PONTIFICIA UNIVERSIDAD JAVERIANA
FACULTAD DE INGENIERIA
SYSTEMS ENGINEERING PROGRAM
BOGOTÁ, D.C.

Noviembre
2022

**PONTIFICIA UNIVERSIDAD JAVERIANA
FACULTAD DE INGENIERÍA
PROGRAMA DE INGENIERÍA DE SISTEMAS**

Rector de la Pontificia Universidad Javeriana

Jorge Humberto Peláez Piedrahita, S.J.

Decano de la Facultad de Ingeniería

Ing. Lope Hugo Barrero Solano

Director de la Carrera de Ingeniería de Sistemas

Ing. Carlos Andrés Parra Acevedo

Director del Departamento de Ingeniería de Sistemas

Ing. Cesar Julio Bustacara Medina

Artículo 23 de la Resolución No. 1 de Junio de 1946

“La Universidad no se hace responsable de los conceptos emitidos por sus alumnos en sus proyectos de grado. Sólo velará porque no se publique nada contrario al dogma y la moral católica y porque no contengan ataques o polémicas puramente personales. Antes bien, que se vean en ellos el anhelo de buscar la verdad y la Justicia”

Agradecimientos

Queremos agradecer a la Pontificia Universidad Javeriana, nuestra alma mater, la cual nos ha formado, guiado y en la cual tenemos experiencias enriquecedoras. A la facultad de ingeniería y el departamento de sistemas, que nos han acompañado y fortalecido constantemente en nuestro proceso educativo. Al Ing. Cesar Julio Bustacara Medina, cuyo apoyo y guía ha sido más que invaluable para el desarrollo de este proyecto. A todos los profesores, cuyas enseñanzas, tanto adentro como afuera de las aulas de clase, se esforzaron tanto y con tanto esmero en entregárnoslas. A nuestros padres y familiares por el infinito apoyo brindado. A todos esos compañeros que nos ayudaron a crecer, mejorar y dar lo mejor de nosotros.

Tabla de Contenidos

Agradecimientos	IV
Lista de Figuras	IX
Lista de Tablas	XI
Abstract	1
1. Introducción	2
2. Descripción General	3
2.1. Problema y Solución	3
2.1.1. Contexto del Problema	3
2.1.2. Formulación del Problema	5
2.1.3. Propuesta de la Solución	6
2.1.4. Justificación de la Solución	6
2.2. Descripción del Proyecto	7
2.2.1. Objetivo General	7
2.2.2. Objetivos Específicos	8
2.2.3. Entregables, Estándares y Justificación	8

3. Contexto del Proyecto	10
3.1. Antecedentes	10
3.1.1. Anatomía del Área de Interés	10
3.1.2. Patología	13
3.1.3. SAHOS y las Almohadillas Adiposas en el Espacio Parafaríngeo . . .	17
3.1.4. Imágenes Médicas	18
3.1.5. Segmentación de Imágenes Médicas	19
3.1.6. Técnicas de Segmentación	21
3.2. Trabajos Relacionados	23
3.2.1. U-Net (Red neuronal convolucional): Organ at Risk Segmentation in Head and Neck CT Images Using a Two-Stage Segmentation Framework Based on 3D U-Net	23
3.2.2. Bidirectional RNN-based Few Shot Learning for 3D Medical Image Segmentation	25
3.2.3. SVM: An Intelligent Diagnosis Method of Brain MRI Tumor Segmentation Using Deep Convolutional Neural Network and SVM Algorithm	26
3.2.4. Automatic MRI Segmentation of Para-pharyngeal Fat Pads Using Interactive Visual Feature Space Analysis for Classification	28
3.2.5. Comparación del Desempeño	29
3.3. Oportunidad	29
4. Análisis del Problema	31
4.1. Contexto del Sistema	31
4.2. Requerimientos	32
4.2.1. Requerimientos Funcionales	32
4.2.2. Requerimientos No Funcionales	34
4.3. Restricciones	35
4.4. Especificaciones Funcionales	36
4.4.1. CU-1: Entrenar Modelo	36

4.4.2. CU-2: Segmentar Imágenes	36
4.4.3. Diagrama de casos de Uso	37
4.5. Priorización	37
5. Diseño de la Solución	39
5.1. Metodología	39
5.2. Arquitectura de la Solución	40
5.2.1. Vista Lógica	40
5.2.2. Vista de Procesos	41
5.2.3. Vista de Implementación	41
5.2.4. Vista Física	42
5.2.5. Vista de Arquitectura de Red Neuronal	43
6. Implementación de la Solución	45
6.1. Fases Metodológicas	45
6.1.1. Fase I: Recopilación de recursos	46
6.1.2. Fase II: Diseño	47
6.1.3. Fase III: Implementación	48
6.1.4. Fase IV: Validación	49
6.2. Producto Final	49
7. Resultados	53
7.1. Funcionalidad de Entrenamiento	53
7.1.1. Tejido Adiposo en Espacio Parafaríngeo	53
7.1.2. BraTS 2020	56
7.2. Funcionalidad de Segmentación	59
7.2.1. Tejido Adiposo en Espacio Parafaríngeo	59
7.2.2. BraTS 2020	61
7.3. Análisis de Resultados	61
7.3.1. Tejido Adiposo en Espacio Parafaríngeo	61
7.3.2. BraTS 2020	62

8. Conclusiones	63
8.1. Análisis de Impacto	63
8.2. Conclusiones y Trabajo Futuro	64
Referencias	65
Apendices	72

Lista de Figuras

3.1.	Anatomía del Cuello [1].	11
3.2.	Espacio parafaríngeo.	13
3.3.	Ejemplo SAHOS [2].	14
3.4.	Arquitectura Red Neuronal Convolutacional U-Net.	21
3.5.	Arquitectura LSTM.	23
3.6.	Arquitectura convolucional LocNet y SegNet.	24
3.7.	Modelo de Segmentación Propuesto en <i>Kim et al.</i> [3].	25
3.8.	Diagrama del modelo [4].	26
3.9.	Diagrama esquemático de procesamiento intermedio [4].	27
3.10.	Pipe Line Propuesto en <i>Rahman et al.</i> [5]	28
4.1.	Diagrama de Contexto del Sistema.	32
4.2.	Diagrama de Casos de Uso del Sistema.	37
5.1.	Vista Lógica del Sistema	40
5.2.	Vista de Procesos del Sistema	41
5.3.	Vista de Implementación del Sistema	42
5.4.	Vista de Física del Sistema	43
5.5.	Arquitectura de Red Neuronal Convolutacional.	44
6.1.	Manual de Uso Integrado.	50
6.2.	Resultado del Entrenamiento	51

6.3. Resultado de la Segmentación	52
7.1. Coeficiente de DICE en Entrenamiento y Validación - Tejido Adiposo.	54
7.2. Precisión en Entrenamiento y Validación - Tejido Adiposo.	54
7.3. Pérdida en Entrenamiento y Validación - Tejido Adiposo.	55
7.4. Coeficiente de DICE en Entrenamiento y Validación - BraTS 2020.	57
7.5. Precisión en Entrenamiento y Validación - BraTS 2020.	57
7.6. Pérdida en Entrenamiento y Validación - BraTS 2020.	58
7.7. Segmentación Realizada por el Algoritmo.	60
7.8. Segmentación Realizada por el Equipo.	60
7.9. Validación Segmentación en BraTS.	61

Lista de Tablas

2.1. Entregables del Proyecto	9
3.1. Factores de riesgo para SAHOS	15
3.2. Sintomatología de SAHOS	16
3.3. Radiación según la región en TC	19
3.4. Métricas de validación	20
3.5. Comparación del Algoritmo de <i>Rahman et al.</i> [5] y los Algoritmos Tradicionales	29
3.6. Comparación de trabajos relacionados.	29
4.1. Drivers Arquitectónicos Priorizados.	38
7.1. Intento con Mejor Resultado - Tejido Adiposo.	56
7.2. Intento con Mejor Resultado - BraTS.	59

Abstract

Obstructive Sleep Apnea and Hypopnea Syndrome (OSAHS) has a great impact on heart disease and the occurrence of cardiovascular accidents in people who have it. There is a correlation between adipose tissue in the parapharyngeal space, areas of airway collapse, and disease severity in people with OSAHS. Therefore, accurate detection of this tissue in medical imaging can be helpful to confirm the presence of OSAHS, its degree of severity and comorbidity conditions. To segment the adipose tissue, and support the investigation of OSAHS, a 3D-Unet convolutional neural network model is proposed. The encoder path uses sigmoid activation to gather more context features to make more accurate detection of this tissue in the decoder path using ReLU activation. This model achieved a DICE coefficient of 80%.

Capítulo 1

Introducción

En el campo de la medicina, la investigación y el estudio de diferentes fenómenos es una actividad sumamente valiosa e indispensable. Estas investigaciones son estudiadas por comunidades médicas, y si tienen la relevancia y la validez suficiente, son recomendadas para su uso práctico en el ámbito clínico. Actualmente, algunos estudios están intentando expandir las aplicaciones de técnicas ya existentes tanto para el diagnóstico de enfermedades como para apoyar investigaciones.

En las páginas de este documento, se presenta y desarrolla una herramienta de segmentación de imágenes médicas en 3D usando aprendizaje profundo, con el objetivo de apoyar a la comunidad de investigación en áreas de la medicina; proporcionando herramientas basadas en nuevos enfoques que pueden ser potencialmente útiles para la investigación de diferentes fenómenos. Enfermedades como el SAHOS, son padecimientos aparentemente inofensivos, sin embargo, estos terminan siendo agravantes de enfermedades cardiovasculares. Además, las técnicas actuales para su diagnóstico y tratamiento pueden llegar a ser dispendiosas tanto para las entidades sanitarias como para los especialistas.

El diagnóstico del SAHOS, a través de la segmentación de imágenes médicas dada la relación que hay entre la presencia de grasa en las paredes del espacio parafaríngeo y el agravamiento de esta enfermedad, está ganando fuerza en el área de la investigación. A pesar de esto, el uso de las técnicas de segmentación, no son lo suficientemente confiables o son intratables para ser utilizadas en este tipo de estudios; como por ejemplo, desarrollar una segmentación de forma manual.

Este proyecto estuvo motivado por el panorama previamente descrito y es indudable que el uso no solo práctico de la herramienta, sino también teórico, puede apoyar diferentes investigaciones en el campo de la medicina.

Capítulo 2

Descripción General

En este capítulo se presentan los aspectos fundamentales respecto al problema que se aborda, la solución propuesta y la descripción del proyecto.

2.1. Problema y Solución

Esta sección define cuál es el contexto del problema, la formulación del problema a tratar, la solución propuesta a dicho problema y la justificación de dicha solución.

2.1.1. Contexto del Problema

Cada día se presentan más problemas de salud en la población mundial. Según la OMS (Organización Mundial de la Salud) se ha observado una tendencia al aumento de la esperanza de vida. Sin embargo, la calidad de ésta ha disminuido. Esto se debe a que enfermedades y padecimientos como el cáncer, la diabetes, las cardiopatías, los accidentes cardiovasculares y las enfermedades respiratorias crónicas son cada vez más frecuentes [6].

Dicho esto, parece evidente que existe un problema respecto a la calidad de vida y la mortalidad a nivel global. Por ello, una de las grandes preocupaciones que tienen los profesionales de la salud es cómo los padecimientos mencionados previamente pueden agravarse e incluso causar sinergias entre sí. Existe variedad de literatura sobre cómo patologías respiratorias crónicas como el EPOC (Enfermedad pulmonar obstructiva crónica), el asma, la fibrosis pulmonar, las enfermedades restrictivas y el SAHOS (Síndrome de Apnea e Hipopnea Obstructiva del Sueño), afectan de manera negativa y significativa a pacientes con

cardiopatías, incluso aumentando sus probabilidades de sufrir accidentes cardiovasculares [7, 8].

Según la definición de SAHOS, este es un trastorno del sueño potencialmente grave que consiste en que la respiración se detiene y reanuda repetidas veces durante el periodo de sueño del paciente[2].

Adicionalmente, el SAHOS es una patología crónica que tiene un gran impacto sobre las cardiopatías y la ocurrencia de accidentes cardiovasculares. La FEC (Fundación Española del Corazón) ha determinado estadísticamente que las mujeres que padecen SAHOS tienen un riesgo 3.5 veces mayor de padecer una cardiopatía. Este riesgo es entre 4 y 5 veces superior en el caso de los hombres [9, 7]. Cabe resaltar que el incremento de los riesgos por SAHOS en los pacientes es independiente de características demográficas (ej. sexo, edad, raza, etc.) u otros riesgos (ej. tabaquismo, alcoholismo, obesidad, diabetes, dislipidemia, hipertensión, etc.) [10, 11].

Otros aspectos a considerar respecto al SAHOS y su impacto en la salud global son los costos directos e indirectos que conlleva tanto su diagnóstico como el tratamiento. En *Ingram et al.* [12] se recopilan, analizan y comparan los costos y otros aspectos relevantes encontrados en estudios de diversas regiones para posteriormente hacer estas estimaciones en Latinoamérica (específicamente en Colombia). Algunos datos importantes son:

- Los pacientes obesos que padecen SAHOS en Estados Unidos de América tienen una tasa de hospitalización más alta que los que no padecen SAHOS.
- Los costos médicos de los pacientes que padecen SAHOS en Estados Unidos de América el año previo a su diagnóstico son cerca del doble comparados con los de años posteriores a su diagnóstico y tratamiento (2.720 USD vs. 1.384 USD).
- Incremento en el uso de servicios de salud y los costos asociados por pacientes que padecen SAHOS no tratado.
- En el año 2006 el costo del diagnóstico del SAHOS en Colombia era mínimo 2.2 salarios mínimos mensuales legales vigentes (SMLMV) y hasta 6.5 SMLMV.

A pesar de que *Ingram et al.* [12], y las demás publicaciones referenciadas en dicho artículo, no poseen los datos más recientes, estos sirven para ejemplificar cuánto le cuesta a los pacientes y a los sistemas de salud el diagnosticar y tratar esta patología.

2.1.2. Formulación del Problema

Como se evidencia en la sección anterior, el diagnóstico de SAHOS es costoso tanto para los pacientes como para los sistemas de salud. Esto se debe a que la sintomatología de esta patología es inespecífica a pesar de ser muy sugerente [13]. Por lo tanto, el diagnóstico de esta patología es difícil. En consecuencia, el estudio diagnóstico más recomendado por los especialistas y el que da los resultados más esclarecedores es la polisomnografía. La polisomnografía es un estudio del sueño que consiste en registrar ciertas funciones corporales por medio de sensores durante el periodo de sueño del paciente. Este estudio se suele realizar en centros especializados del sueño. El realizar un examen como la polisomnografía es costoso en términos económicos (entre €320 - €650 en España, \$8.000 - \$10.000 en México y \$1.000 - \$7.000 en Estados Unidos de América) [14, 15, 16] y de tiempo (entre 6 y 8 horas aproximadamente).

Existen otros métodos para diagnosticar este padecimiento (Examen Físico, Cuestionario de Berlín, etc.), sin embargo, los resultados de estos son poco concluyentes o incurren en costos similares a los de la polisomnografía pero con menor certeza [17]. Por otro lado, el estudio diagnóstico de enfermedades respiratorias por medio del análisis de las estructuras y características de las vías respiratorias a través de imágenes médicas es una práctica cada vez más frecuente. Para realizar este análisis, los radiólogos suelen subdividir las imágenes manualmente en sus partes constituyentes u objetos, esta práctica es conocida como “segmentar” [18]. Al final de este proceso, el experto puede sacar conclusiones y realizar un diagnóstico basado en los hechos. A pesar de que este tipo de segmentación es considerado el estándar de oro, puede llegar a consumir mucho tiempo. Por esta razón, además de la segmentación manual, aparece la segmentación de carácter semiautomático y totalmente automático, propuestas más rápidas que suelen carecer de calidad en comparación con la segmentación manual. No obstante, día a día se desarrollan nuevas tecnologías que van reduciendo la brecha [18].

El diagnóstico de algunas patologías por medio de imágenes médicas aún es materia de estudio. Esto se debe a que aún no hay resultados concluyentes y certeza respecto a todos los mecanismos detrás de las causas de las patologías. Para obtener certeza y resultados concluyentes de dichos mecanismos es necesario disponer de una gran volumen de datos de calidad. El acceso a estos datos requeridos suele ser limitado, generando escasez para la realización de los estudios.

La escasez de datos previamente mencionada es principalmente causada por la dificultad y el costo de tener suficientes imágenes cuyas segmentaciones tengan la calidad requerida para ver los mecanismos detrás de las patologías. Entre los estudios que se ven afectados por dicha escasez se encuentra el del SAHOS [5, 19, 20, 21, 22]. Por lo tanto, es una

necesidad desarrollar herramientas de segmentación de imágenes médicas que apoyen a los investigadores en sus estudios. Dicho esto, el presente proyecto se propone responder la siguiente pregunta:

¿Puede una herramienta de segmentación semiautomática de imágenes médicas tener la suficiente calidad de segmentado y eficiencia para apoyar la investigación del SAHOS?

2.1.3. Propuesta de la Solución

Teniendo en cuenta el uso de otras técnicas diagnósticas, y estudiando su efectividad en el desarrollo de enfermedades como el SAHOS, en este caso termina siendo igual o incluso más costoso realizar un diagnóstico de SAHOS de forma tradicional (realizando una polisomnografía). Esto se debe a que un experto debe destinar largas jornadas para procesar esas imágenes, analizarlas y finalmente dar un diagnóstico sobre la enfermedad [23].

Con la aparición de nuevas técnicas de procesamiento de imágenes basadas en diferentes tecnologías, surgen nuevas formas de agilizar el proceso de segmentación de tejidos. El aprendizaje profundo es una tecnología que se está desenvolviendo en el campo de la medicina y concretamente en la segmentación de imágenes médicas. Muchos modelos basados en este aprendizaje, presentan resultados sorprendentes en diferentes estudios [24, 25]. Los tiempos de segmentación y los costos asociados se pueden reducir significativamente con ayuda de un algoritmo que automatice este procedimiento y obtenga resultados similares.

En ese orden de ideas, como propuesta a este problema, se desea diseñar y construir un algoritmo de segmentación semiautomática de tejido adiposo sobre MRI, cuyo propósito principal es ser una herramienta de investigación en estudios como el del SAHOS.

2.1.4. Justificación de la Solución

El síndrome de apnea necesita una evaluación médica completa y requiere estudios paracéntricos completos para confirmar su presencia, su grado de severidad y estados comórbidos. El método diagnóstico de referencia es el polisomnograma basal (o de diagnóstico), estándar de oro de acuerdo a los niveles de recomendación de la academia americana de medicina de sueño (AASM, por sus siglas en inglés). Esta técnica registra 15 o más eventos respiratorios por hora de sueño. El registro polisomnográfico se debe realizar cerca de 6 horas por la noche, o en el pico de mayor somnolencia, y en todas las posiciones corporales. Además, un estudio atendido necesita la presencia constante de un técnico. El técnico tiene

que controlar al paciente por conservación directa o con un sistema de video sincronizado con el estudio. Con esto se quiere reflejar todas las implicaciones que existen al llevar a cabo un diagnóstico tradicional [26].

Existe una correlación entre el área de las almohadillas de grasa en varios niveles anatómicos, las zonas de colapso de la pared lateral de las vías respiratorias y la gravedad de la enfermedad en pacientes adultos con apnea [19]. A pesar de que no existe un estudio concluyente al respecto, se piensa que es debido a la escasez de los datos. El diagnóstico de este fenómeno se hace por medio de la detección y evaluación del tejido adiposo por medio de la segmentación de imágenes médicas; generalmente TC (tomografías computarizadas) y MRI (resonancias magnéticas).

Como se mencionó anteriormente, además de la segmentación manual, existe la segmentación de carácter semiautomático y totalmente automático; propuestas más rápidas, basadas en diferentes tecnologías, que están alcanzando la calidad y precisión de una segmentación manual [27, 28, 29]. En un estudio realizado para comparar y evaluar la segmentación manual y semiautomática de la cavidad nasal, donde se utilizaron un conjunto de datos de TC que constan de 98 cortes transversales, el tiempo que tomó la segmentación se redujo de 960 minutos con segmentación manual, a 215 minutos con segmentación semiautomática [30], un resultado que soporta lo anterior.

Se piensa que la presencia de un modelo de segmentación semiautomática, para apoyar estudios relacionados con la búsqueda de nuevos tratamientos del SAHOS y otras enfermedades respiratorias, sería beneficioso, no solo para reducir los costos en términos de tiempo y recursos en estudios de cohorte epidemiológico, sino también como una posible herramienta de apoyo diagnóstico.

2.2. Descripción del Proyecto

Esta sección define cuál es el objetivo general y los objetivos específicos que se satisfacen con la realización del presente proyecto. Asimismo, se presentan los documentos entregables del trabajo de grado, los estándares asociados y la justificación de estos documentos.

2.2.1. Objetivo General

Diseñar e implementar una solución computacional de carácter semiautomática para segmentar el tejido adiposo de la región parafaríngea con un coeficiente de DICE de al

menos el 85 % (el coeficiente de DICE es una estadística utilizada para medir la similitud de dos muestras).

2.2.2. Objetivos Específicos

- Analizar diferentes técnicas de aprendizaje profundo para segmentación de resonancias magnéticas en 3D.
- Realizar el prototipado de las diferentes técnicas analizadas para encontrar la más prometedora.
- Construir la solución final de acuerdo con los prototipos realizados.
- Realizar pruebas de la solución final y validación por parte de los expertos médicos.

2.2.3. Entregables, Estándares y Justificación

Se optó por utilizar un conjunto de estándares pensados para el manejo de proyectos basados en investigación y desarrollo de software, estos son listados y justificados en la tabla 2.1.

Entregable	Estándares asociados	Justificación
SRS (Especificación de Requisitos de Software)	ISO/IEC 25010 [31]	Documento en el cual se especifican los requerimientos funcionales y no funcionales del sistema y/o atributos de calidad
SAD (Documento de Arquitectura de Software)	ISO/IEC 25010 [31], ADD [32], UML	Documento de diseño de la arquitectura, donde se especificarán las decisiones de diseño tomadas para la realización del proyecto, teniendo en cuenta los requerimientos funcionales, no funcionales, atributos de calidad, preocupaciones y demás drivers arquitectónicamente relevantes para el proyecto
Plan de Pruebas		Plan de pruebas donde se especifican las pruebas a las cuales el software generado de este proyecto se va a someter para asegurar la calidad, completitud y correcta funcionalidad.
Documento de Pruebas		Documento en el cual se van a colocar los resultados de las pruebas en métricas medibles y comprobables respecto a la calidad y el desempeño del software generado del proyecto
Memoria de Trabajo		Documento en el cual se especifica todo el proceso realizado por los miembros del grupo para el diseño y desarrollo del proyecto y su implementación
Implementación Final	Investigación Basada en diseño [33], SCRUM [34]	Resultado final de la implementación, el cual incluye código fuente, red o redes neuronales convolucionales entrenadas y sin entrenar, documentación para uso del mismo software y métricas sobre la precisión y desempeño del software respecto a su principal funcionalidad.
Proceso de Diseño	ADD [32]	Documento en el cual se evidencia el proceso y decisiones de diseño que generaron la arquitectura del sistema.
Plan de Proyecto	Investigación Basada en diseño [33], SCRUM [34]	Planeación y especificación de las fases metodológica junto con las actividades pensadas para la ejecución y gestión del proyecto.

Tabla 2.1: Entregables del Proyecto.

Capítulo 3

Contexto del Proyecto

En este capítulo se exploran y explican diversos conceptos de la medicina, la computación visual y la inteligencia artificial necesarios para el desarrollo del proyecto. También se exponen el cómo estos se relacionan entre sí. Posteriormente, se exponen soluciones similares y trabajos relacionados, esto con el fin de compararlos para identificar oportunidades y otros aspectos relevantes para el proyecto.

3.1. Antecedentes

En esta sección se encuentran los conceptos principales que permiten el desarrollo del trabajo de grado. Estos conceptos se dividen en dos partes: conceptos médicos y conceptos técnicos. En los conceptos médicos se presentan las definiciones de la zona médica de interés, el problema en torno al proyecto y las herramientas utilizadas para visualizar dicha zona. Por otro lado, los conceptos técnicos exponen las definiciones y ejemplos de las técnicas de inteligencia artificial utilizadas para el desarrollo del proyecto.

3.1.1. Anatomía del Área de Interés

El cuello es una región del cuerpo comprendida entre la cabeza y el tórax. Esta región se caracteriza principalmente por ser una vía de paso de elementos respiratorios, vasculares, viscerales y nerviosos. Su forma es cilíndrica, sin embargo, su longitud y ancho varía de un individuo a otro por factores como la genética, la edad, el sexo y el peso[1].

En la figura 3.1 se puede apreciar con gran detalle la composición anatómica del cuello.

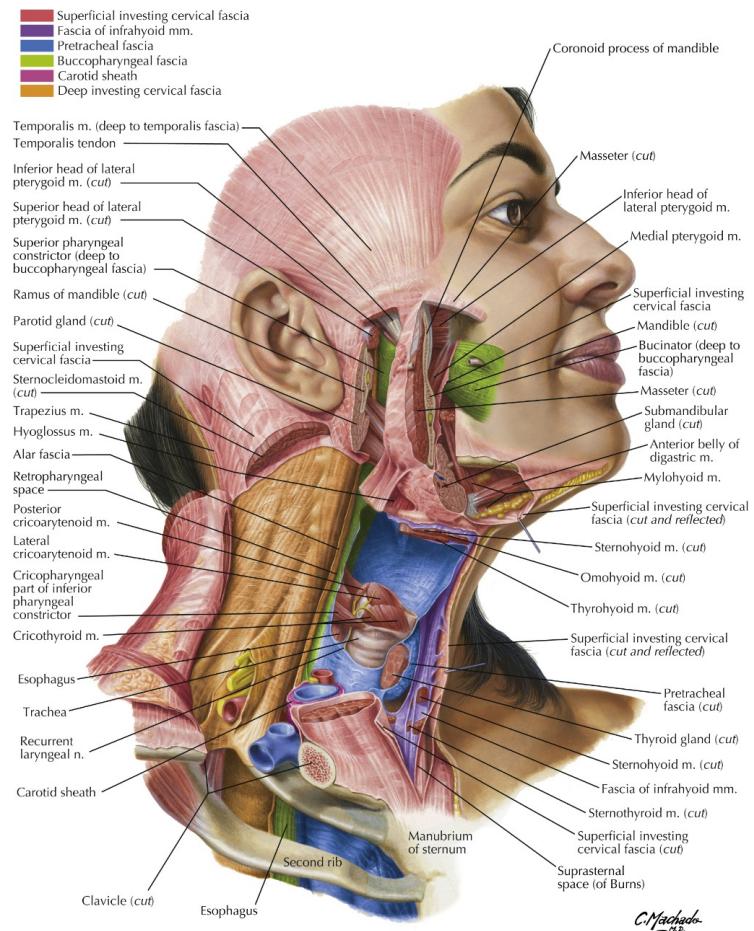


Figura 3.1: Anatomía del Cuello [1].

De acuerdo con la imagen presentada, y para fines del entendimiento del presente proyecto, a continuación se describen los límites que comprenden la estructura anatómica de interés [1].

El límite superior y superficial del cuello se encuentra comprendido por:

- El borde inferior horizontal de la mandíbula.
- Borde posterior de rama ascendente mandibular.
- Línea horizontal desde articulación temporomaxilar hasta protuberancia occipital externa.

- Línea curva occipital superior.

Internamente, este límite está comprendido por:

- Base del cráneo entre apófisis, pterigoides, apófisis estiloides, protuberancia occipital externa y borde posterior de rama ascendente de la mandíbula.

Por otro lado, el límite inferior y superficial se encuentra comprendido por:

- Borde superior del manubrio esternal
- Cara superior de ambas clavículas
- Línea horizontal que une ambas articulaciones acromioclaviculares, pasando por apófisis de la séptima vértebra cervical (C7).

Internamente, este límite está comprendido por (estos límites corresponden al vértice del tórax):

- Plano oblicuo que pasa por el disco intervertebral entre C7 y primera vértebra torácica (T1).
- Cara superior de la primera costilla.
- Borde superior del manubrio esternal.

Dentro de los límites previamente delimitados es posible establecer una división por espacios [1, 35, 36]. Algunos de estos son: el Masticador, el Carotídeo, el Parotídeo, el Faringomucoso, el Perivertebral, el Retrofaríngeo y el Parafaríngeo, este último siendo el espacio de interés para el desarrollo del presente proyecto. En la figura 3.2 se puede apreciar el espacio parafaríngeo desde distintas vistas con su respectiva segmentación.

El espacio parafaríngeo (EPF) es una área con forma de pirámide invertida, esta se encuentra entre la base del cráneo y el hueso hioideo [36, 35]. En la literatura médica también se suele reconocer esta área por los nombres de “Espacio Parafaríngeo Preestiloideo” y “Espacio Parafaríngeo Postestiloideo” siendo estos dos términos más comúnmente usados para diferenciar entre dos zonas específicas que son comprendidas dentro del EPF.

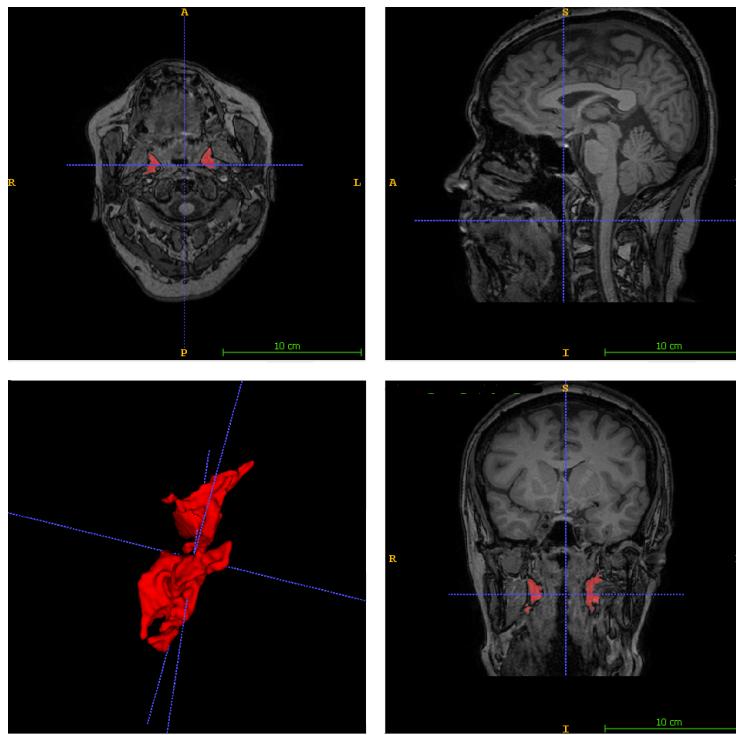


Figura 3.2: Espacio parafaríngeo.

El EPF contiene un pequeño segmento del nervio craneal V_3 , un pequeño tramo de la arteria maxilar interna, un pequeño tramo de la arteria faríngea, un pequeño tramo del plexo venoso pterigoideo, restos de glándulas salivales menores y principalmente tejido adiposo [36, 35]. Este último siendo el principal tejido de interés para el presente proyecto. La relevancia de dicho tejido es expuesta posteriormente en esta sección.

3.1.2. Patología

El síndrome de apnea-hipopnea obstructiva del sueño (SAHOS) es un padecimiento crónico y progresivo. Se estima que tiene una prevalencia del 5% de la población adulta y un 2% de la población pediátrica. Suele ser más frecuente en hombres y a medida que aumenta la edad [13].

El SAHOS es un trastorno en el cual quien lo padece deja de respirar parcial o totalmente en repetidas ocasiones durante el periodo de sueño. Es característico de este padecimiento el recurrente colapso parcial o total de la vía aérea, que desencadena una

disminución o cese del flujo de aire. El SAHOS es causado por un desbalance en el calibre de la vía aérea y el tono motor de la lengua o de los músculos encargados de la dilatación de las vías respiratorias. Dado que se generan interrupciones en el flujo de aire, la saturación de oxígeno puede caer y aumentar la presión parcial de CO_2 . Se estima que el 35 % de los pacientes con SAHOS presenta hipertensión arterial y se asocia a 2 veces más riesgo de hipertensión pulmonar y 4 veces más riesgo de accidente cerebro vascular en comparación con la población general [37].

En la figura 3.3 se pueden apreciar 2 ejemplos. En el ejemplo de la parte inferior de la imagen, se muestra un paciente con el trastorno: la lengua cae cerrando la vía aérea, causando problemas respiratorios y ronquidos por tratar de mover la lengua para que fluya el aire. En el ejemplo de la parte superior de la imagen se puede ver cómo es el flujo de aire en un paciente sin SAHOS [2].

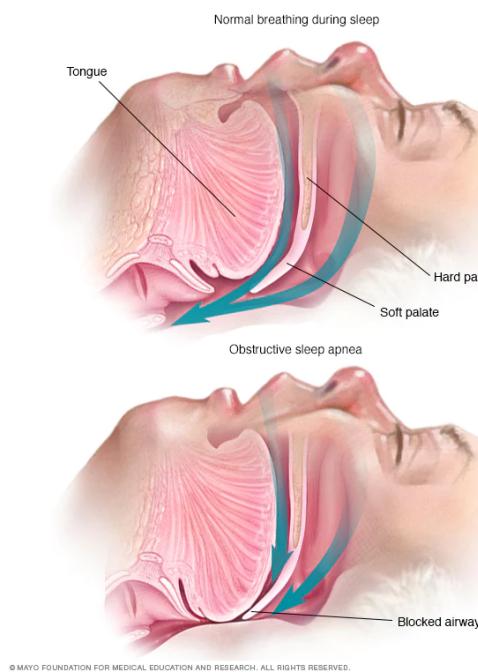


Figura 3.3: Ejemplo SAHOS [2].

Teniendo en cuenta la descripción de este trastorno, en la tabla 3.1 se recopilan los diversos factores de riesgo para padecer SAHOS [38, 17].

Modificables	No Modificables
Obesidad	Sexo masculino
Tabaquismo	Edad
Endocrinopatías: Hipotiroidismo, Acromegalia	Postmenopausia
Patología nasal: Rinitis alérgica, desviación septal	Agregación familiar
Hipertrofia amigdalina obstructiva	Síndrome de down
	Sindromede ovario poliquístico
	Malformaciones cráneo-faciales
	APOE4

Tabla 3.1: Factores de riesgo para SAHOS.

También se ha detectado que los pacientes que cumplen una o más de las siguientes características tiene una propensión más alta de padecer SAHOS [38, 17, 2]:

- Obesidad (IMC > 35)
- Insuficiencia Cardíaca
- Fibrilación Auricular
- Hipertensión Refractaria
- Diabetes Mellitus tipo 2
- Arritmias Nocturnas
- Accidentes Cerebrovasculares
- Hipertensión Pulmonar
- Preoperatorio de cirugía bariátrica
- Enfermedades respiratorias crónicas con deterioro gasométrico mayor al esperado

Usualmente, se asocia el roncar y la hipersomnolencia diurna como los principales síntomas SAHOS. Sin embargo, estos no son los únicos síntomas. La sintomatología de SAHOS se puede dividir en síntomas diurnos y nocturnos. Dichos síntomas se encuentran en la tabla 3.2 [38].

Sintomas Diurnos	Sintomas Nocturnos
Hipersomnolencia	Ronquidos
Sueño poco reparador	Apneas presenciadas
Cefalea matutina	Asfixias
Irritabilidad	Movimientos anormales
Apatía	Nicturia
Síntomas depresivos	Insomnio
Alteración de la concentración en la memoria	Reflujo gastroesofágico
Disminución de la libido e impotencia	Polidipsia
Sequedad faríngea y bucal matutina	Diaforesis
	Congestión Nasal
	Salivación excesiva
	Pesadillas

Tabla 3.2: Sintomatología de SAHOS.

Adicionalmente, se han identificado algunas características físicas que indican una predisposición para padecer SAHOS[13]:

- Obesidad
- Cuello corto y ancho
- Exploración Otorrinolaringológica:
 - Obstrucción nasal
 - Hipertrofia de amígdalas y/o úvula
 - Paladar blando largo
 - Retro y micrognatía
 - Visualización disminuida de estructuras de cavidad oral (Grados de Mallampati)
- Hipertensión arterial
- Arritmias
- Malformaciones cráneo-faciales

Realizar un diagnóstico de SAHOS requiere la realización de un estudio polisomnográfico. Este consiste en detectar la frecuencia en la que suceden eventos respiratorios conocidos

como apnea e hipopnea durante el periodo de sueño del paciente. La apnea o hipopnea se definen como eventos donde el paciente deja de respirar total o parcialmente por 10 o más segundos, esto generando reducción en la amplitud de la señal de flujo respiratorio (mayor o igual del 90 % para la apnea y mayor o igual al 30 % para la hipopnea)[37, 38, 13]. A su vez, esto genera una desaturación de oxígeno mayor o igual al 4 % y/o alertamiento por parte del paciente. Durante la polisomnografía, la detección de los eventos respiratorios se realiza por medio de mediciones multicanal. Estas permiten determinar el tiempo y etapas del sueño, esfuerzo respiratorio, flujo de aire, ritmo cardíaco, oximetría y movimientos de las extremidades [37]. El índice de apnea-hipopnea (IAH) es la principal medida que da como resultado la polisomnografía respecto al diagnóstico de SAHOS. Este es el promedio de eventos respiratorios por hora. Se considera que el paciente padece SAHOS si tiene un IAH mayor o igual a 5, la severidad del padecimiento es leve cuando el IAH está entre 5 y 15, moderado entre 15 y 30 y grave cuando es mayor a 30 [37, 13, 38, 26].

3.1.3. SAHOS y las Almohadillas Adiposas en el Espacio Parafaríngeo

Como se mencionó previamente, el SAHOS es un padecimiento que genera deterioro a la salud de quien lo padece. Existen reportes que indican que este padecimiento empeora con el aumento de masa corporal y mejora por la reducción de esta.

Los expertos creen que una de las principales causas del SAHOS es una combinación de diversas predisposiciones causadas por factores anatómicos y respuestas neuromusculares compensatorias alteradas. No obstante, los mecanismos exactos que generan este padecimiento aún no son entendidos a cabalidad. A pesar de ello, reportes parecen indicar que el colapso en las vías aéreas podría depender de la localización de un exceso de tejido adiposo visceral. Sin embargo, aún no hay evidencia contundente del cómo y cuáles de estos excesos afectan este padecimiento de forma precisa [21, 22].

Algunas investigaciones han revelado lo siguiente:

- El tejido adiposo en el espacio parafaríngeo es significativamente más grande y la distancia entre el hueso hioideo y la espina cervical es más larga en pacientes con SAHOS que en los pacientes que solo son roncadores habituales [21].
- Pacientes con SAHOS han mostrado tener más tejido adiposo parafaríngeo que los controles emparejados con el índice de masa corporal en la resonancia magnética [19].

- Estudios en tomografías computarizadas sugieren que el tejido adiposo parafaríngeo y la distribución de la grasa en el cuello parece jugar un rol importante en el desarrollo en etapas tempranas de SAHOS en pacientes obesos [19].
- Se ha podido apreciar que el área de tejido adiposo parafaríngeo a nivel subglosos-supraglótico tiene una correlación con el IAH [19].
- Solo se ha encontrado evidencia concluyente en la relación entre las anormalidades de la vía aérea y el SAHOS en pacientes jóvenes y sin sobre peso [20].
- El colapso de las vías aéreas es causado primariamente por la presión circundante [22].
- El volumen de tejido adiposo parafaríngeo podría ser un factor importante en la fisiopatología y la progresión en SAHOS en pacientes con sobrepeso [21].

3.1.4. Imágenes Médicas

Algunas de las técnicas usadas frecuentemente para el mapeo de las vías respiratorias son las tomografías computarizadas (TC) y las imágenes por resonancia magnética (MRI por sus siglas en inglés). Las TC combinan una serie de radiografías que se toman desde diferentes ángulos alrededor del cuerpo y se procesan para crear imágenes (o cortes) transversales de los huesos, vasos sanguíneos y tejidos blandos. Al igual que las TC, las MRI también generan imágenes detalladas de áreas internas del cuerpo, pero utilizan ondas de radio [39].

Aunque la TC se considera el estándar para la generación de imágenes en el diagnóstico de enfermedades respiratorias, gracias a la calidad que ofrece sobre regiones como los pulmones y las vías respiratorias [40], la cantidad de radiación ionizante que introduce al paciente es un tema preocupante. A pesar de que la radiación ionizante está presente de forma natural en el ambiente, la sobreexposición puede ocasionar cáncer y otros daños sobre la salud. Para tener una idea, en la tabla 3.3 se muestra cuanta radiación se puede llegar a recibir durante una sesión, listando las regiones más comunes en las cuales se realiza el procedimiento, junto con la radiación ambiente análoga recibida. La cantidad de radiación se puede controlar, el problema es que esta es proporcional con la calidad de las imágenes generadas. De hecho, los expertos a menudo usan el término “dosis efectiva” para describir el balance que debe existir entre calidad y radiación recibida por el paciente [41, 42].

La MRI como método de examen no basado en radiación ha ganado popularidad en el ámbito clínico y epidemiológico. La resonancia magnética es una alternativa prometedora,

Procedimiento	Radiación	Radiación ambiente equivalente
Vientre y pelvis	10 mSv	3 años
Colono grafía	6 mSv	2 años
Cabeza y pelvis	2 mSv	8 meses
Espina	7 mSv	2 años

Tabla 3.3: Radiación según la región en TC

especialmente para estudios en serie, gracias a que proporciona imágenes funcionales estructurales sin radiación ionizante. Sin embargo, ha tenido un uso clínico limitado debido a la baja intensidad de la señal. A pesar de esto, existen mejoras técnicas para ampliar su uso en otras áreas, como por ejemplo su uso en investigaciones de diagnóstico de enfermedades vasculares como la hipertensión muscular o enfermedades complejas como la fibrosis quística [43].

En un documento de posición de la sociedad Fleischner, se presenta una forma de expandir las aplicaciones de la resonancia magnética pulmonar en la evaluación clínica de los trastornos pulmonares. En ese documento se exponen técnicas recientes de resonancia magnética, incluido el tiempo de eco ultracorto y el tiempo de eco cero [44]. La idea principal de este tipo de estudios es ampliar las oportunidades clínicas para resonancia magnéticas. Este proyecto aprovecha estos hechos y además hace uso de MRI por las siguientes razones:

- Proporciona un buen contraste entre las estructuras de los tejidos blandos y se utiliza para estudiar los tejidos del cerebro y la garganta.
- Sobresale en la detección de algunas enfermedades que la TC no puede [39].
- La falta de radiación hace que la resonancia magnética sea una modalidad ideal para exámenes pediátricos, mujeres embarazadas y pacientes que requieren seguimiento en serie y longitudinal [44].

3.1.5. Segmentación de Imágenes Médicas

La segmentación de imágenes médicas suele ser el primer paso para la mayoría de los procedimientos de análisis. Consiste en extraer la región o el objeto de interés de una imagen médica (2D o 3D). Esta puede ser realizada de forma manual, semiautomática o totalmente automática [45]. Los métodos de segmentación automática de imágenes médicas

a menudo se derivan de las técnicas más modernas de segmentación de imágenes. Las diferentes técnicas de segmentación incluyen métodos tradicionales: segmentación de umbral, segmentación por crecimiento de región, métodos de clasificación y agrupación: k vecinos más cercanos (KNN), medias C difusas (FCM), modelo de campo aleatorio de Monte Carlo (MRF), segmentación guiada basada en conjuntos de datos, maximización de expectativas (EM), métodos bayesianos, máquinas de vectores de soporte (SVM), redes neuronales artificiales (ANN), métodos de bosque aleatorio, redes neuronales convolucionales (CNN) y métodos de modelo de deformación: modelos de deformación paramétrica, modelos de deformación geométrica [46].

La comparación de imágenes para evaluar la calidad de la segmentación es esencial para medir el progreso en esta área de investigación. Los desafíos más relevantes para su evaluación son: la selección de métricas, la ambigüedad en definiciones de ciertas métricas en la literatura y la ineficiencia de las implementaciones para calcularlas [47]. En la tabla 3.4 se presenta el conjunto de métricas seleccionadas para la validación de la segmentación de imágenes en 3D. Se estudió tanto el contexto como la literatura médica investigada para realizar la selección.

Métrica	Símbolo	Expresión/descripción
Tasa de verdaderos positivos	TPR	Indica el número de unidades marcadas como positivas y en la segmentación base eran positivas.
Tasa de falsos positivos	FPR	Vóxeles marcados como falsos y en la imagen estaban como positivos.
Tasa de verdaderos negativos	TNR	Indica el número de unidades marcadas como positivas y en la segmentación base eran negativas.
índice de Dice	$DICE$	Estadístico utilizado para comparar la similitud de dos muestras.
Sensibilidad		$Sens = TP/TP + FN$
Precisión		$Spec = TN/TN + FP$

Tabla 3.4: Métricas de validación

3.1.6. Técnicas de Segmentación

Una opción para poder hacer la segmentación de imágenes médicas de forma semiautomática o automática es el uso de aprendizaje profundo (campo de la inteligencia artificial). Dentro de este aprendizaje existen varias técnicas o arquitecturas de redes neuronales que han sido desarrolladas y probadas en este campo de segmentación de imágenes con gran éxito. En general, el proceso que siguen estas técnicas es similar: se toman las imágenes como entrada y se le asignan importancias (pesos) a ciertos elementos dentro de la imagen para así poder diferenciarlos [48]. Sin embargo, para este proceso hay arquitecturas que han sido más investigadas, usadas y además han sobresalido. Dentro de estas se encuentran las redes neuronales convolucionales (CNN por sus siglas en inglés) y las redes neuronales recurrentes (RNN por sus siglas en inglés) [49].

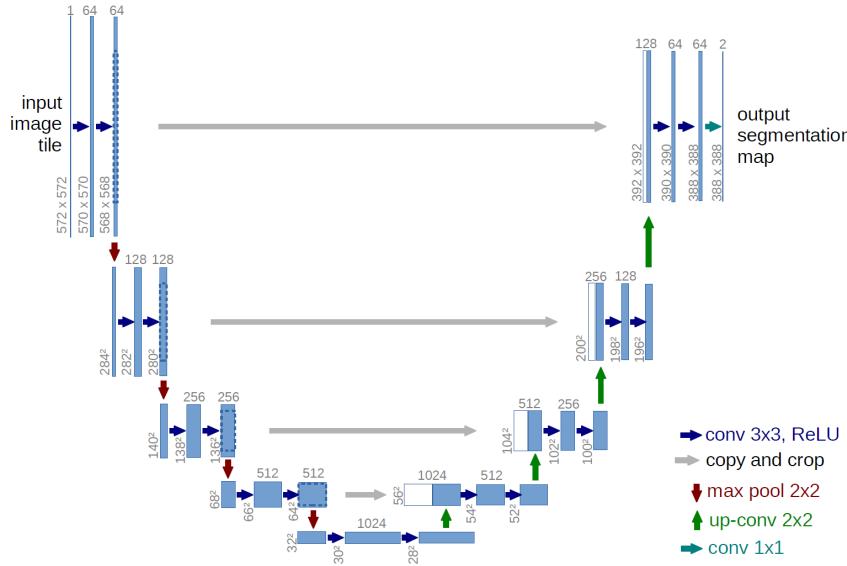


Figura 3.4: Arquitectura Red Neuronal Convolucional U-Net.

En *Chauhan et al* [50], se explica que las CNN son algoritmos de aprendizaje profundo que toman imágenes de entrada y las convolucionan (transforman la imagen de entrada) con filtros o núcleos para extraer características. Una imagen $N * N$ se convoluciona con un filtro $f * f$ y esta operación de convolución aprende la misma característica de la región local que está procesando en toda la imagen. La ventana (recorrido en la imagen) se desliza después de cada operación para evaluar las otras regiones locales y las características son aprendidas por los mapas de características. Los mapas de características capturan el

campo receptivo local de la imagen y trabajan con pesos y sesgos compartidos. Estas CNN contienen varias capas, donde las primeras puedan detectar líneas, curvas, etc. y así se van especializando hasta poder reconocer formas complejas como un rostro, siluetas y demás. En la figura 3.4 se observa una de las arquitecturas más conocidas en las redes neuronales convolucionales: la red U-Net.

Por otro lado, *Hesamian et al.* [51] explica que la RNN está dotada de conexiones recurrentes que permiten a la red memorizar los patrones de las últimas entradas. Teniendo en cuenta que el ROI en las imágenes médicas suele estar distribuido en múltiples cortes adyacentes (por ejemplo, en TC o MRI), hace que haya correlaciones en los cortes sucesivos. En consecuencia, las RNN son capaces de extraer contextos entre los cortes de entrada como una forma de datos secuenciales. La estructura de las RNN consta de dos secciones principales de extracción de información intracorte que puede ser realizada por cualquier tipo de modelo CNN y la RNN encargada de la extracción de información intercorte.

Dentro de estos tipos de RNN, la más usada es la arquitectura Long Short Term Memory (LSTM). Las LSTM se ocupan tanto de la memoria a largo plazo (LTM, por sus siglas en inglés) como de la memoria a corto plazo (STM por sus siglas en inglés) y, para que los cálculos sean sencillos y eficaces, utilizan el concepto de puertas [52].

- **Puerta del olvido:** La LTM pasa a la puerta del olvido y olvida la información que no es útil.
- **Puerta de aprendizaje:** El evento (entrada actual) y la STM se combinan para que la información necesaria que se ha aprendido recientemente de la STM pueda aplicarse a la entrada actual.
- **Puerta del recuerdo:** La información LTM que no se ha olvidado y el STM y el Evento se combinan juntos en la puerta del recuerdo que funciona como un LTM actualizado.
- **Puerta de uso:** Esta puerta también utiliza LTM, STM y Evento para predecir la salida del evento actual que funciona como un STM actualizado.

Para comprender mejor las LSTM, en la figura 3.5 se encuentra un ejemplo de su arquitectura donde se pretende predecir la imagen de un lobo teniendo en cuenta las características de gatos y perros contenidas en sus puertas.

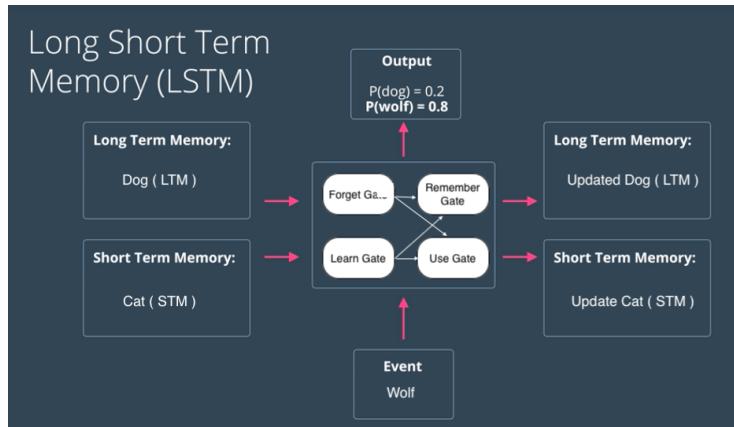


Figura 3.5: Arquitectura LSTM.

3.2. Trabajos Relacionados

En esta sección se presentan 4 soluciones relacionadas con el trabajo de grado propuesto utilizando aprendizaje profundo. Estas soluciones son descritas de una forma global, destacando el uso del aprendizaje profundo y sus resultados. Cada solución utiliza una arquitectura diferente y son comparadas al final en una tabla con la métrica Dice Score.

3.2.1. U-Net (Red neuronal convolucional): Organ at Risk Segmentation in Head and Neck CT Images Using a Two-Stage Segmentation Framework Based on 3D U-Net

En este estudio, se concatenan dos U-Nets 3D para segmentar una estructura objetivo, donde la primera U-Net 3D se utilizó para localizar un volumen objetivo relativamente pequeño que encerraba la estructura objetivo y la segunda U-Net 3D se utilizó para segmentar la estructura objetivo del volumen objetivo. La primera y la segunda red se denominan LocNet y SegNet, respectivamente. Como se muestra en la figura 3.6, LocNet y SegNet tienen la misma estructura de red, que consiste en una ruta de análisis y una ruta de síntesis. En la ruta de análisis, cada capa contiene dos convoluciones de $3 \times 3 \times 3$, cada una de las cuales va seguida de una normalización por lotes (BN) y una unidad lineal rectificada (ReLU) y luego un pooling máximo de $2 \times 2 \times 2$ con pasos de dos en cada dimensión. En la ruta de síntesis, cada capa consiste en una convolución ascendente de $2 \times 2 \times 2$ con pasos

de dos en cada dimensión, seguida de dos convoluciones de $3 \times 3 \times 3$ cada una, seguidas de una BN y una ReLu. Las conexiones de acceso directo desde capas de igual resolución en la ruta de análisis proporcionan características esenciales de alta resolución para la ruta de síntesis. En la última capa, se utiliza una convolución $1 \times 1 \times 1$ para reducir el número de canales de salida a una clasificación 0-1. En total, cada red tiene 17 capas convolucionales [25].

La primera U-Net 3D, denominada LocNet, se utiliza para localizar a grandes rasgos la estructura objetivo con un cuadro delimitador. Las imágenes recortadas y las máscaras se reducen primero a una resolución de $96 \times 96 \times 56$ en píxeles y se utilizan para entrenar la LocNet. LocNet proporciona una clasificación de 0 a 1 para cada píxel, indicando si un píxel se encuentra en el cuadro delimitador. Se utiliza un paso de posprocesamiento para generar un cuadro delimitador de tamaño $(h/4) \times (w/4) \times (k/4)$ a partir del resultado de LocNet y el cuadro delimitador se transfiere de nuevo al marco de coordenadas del volumen recortado. A continuación, el cuadro delimitador se aplica al volumen recortado para obtener un volumen más pequeño de tamaño $h \times w \times k$, que es el volumen objetivo. Se entrena una LocNet para cada estructura objetivo, que requiere un cuadro delimitador de un tamaño específico [25].

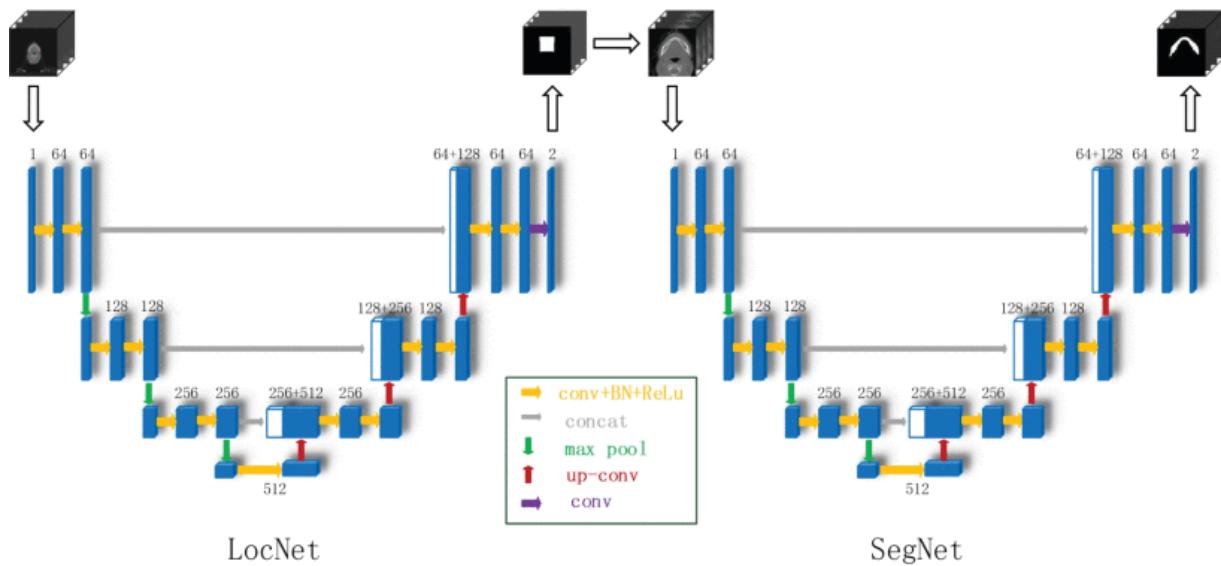


Figura 3.6: Arquitectura convolucional LocNet y SegNet.

La segunda U-Net 3D, denominada SegNet, se utiliza para segmentar la estructura objetivo a partir del volumen objetivo obtenido en el paso anterior. El volumen objetivo

tiene un tamaño de $h \times w \times k$, que es mucho menor que el volumen recortado de $384 \times 384 \times 224$ y solo se segmenta una estructura a partir de él. Estas dos características facilitan la segmentación de SegNet. El resultado de SegNet es un volumen de máscara en el que cada píxel es 0 ó 1, lo que indica los píxeles de fondo y de destino, respectivamente [25].

3.2.2. Bidirectional RNN-based Few Shot Learning for 3D Medical Image Segmentation

Los autores proponen un nuevo marco para segmentación de imágenes médicas de pocos disparos. Este modela la relación entre los datos de consulta y de soporte de otras diversas tareas de pocos disparos en conjunto con la información estructural tridimensional entre cortes adyacentes. Con este fin, el marco propuesto integra una unidad recurrente bidireccional (GRU) entre el codificador y el decodificador de un modelo de segmentación en pocos disparos 2D para un aprendizaje de representación eficiente. De esta forma, las características codificadas tanto del conjunto de soporte como de segmentos adyacentes capturan características clave para predecir en las capas de decodificación la segmentación de una imagen de consulta [3].

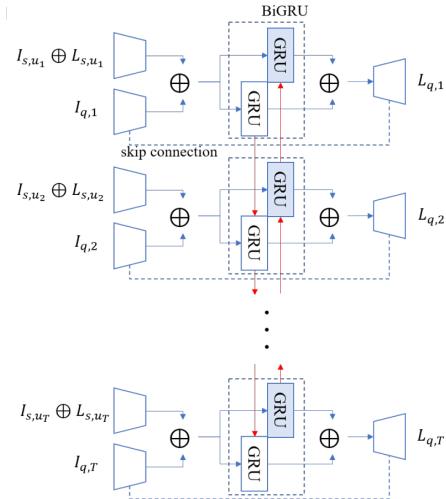


Figura 3.7: Modelo de Segmentación Propuesto en *Kim et al.* [3].

El modelo propuesto realiza la segmentación en 3 fases. En la primera, las características de soporte y consulta son extraídas por medio de 2 codificadores separados. En la

segunda, un GRU bidireccional modela la relación entre características extraídas de los cortes adyacentes. Finalmente, en la tercera fase, haciendo uso de mapas de características y características de bajo nivel, el decodificador predice la segmentación. El modelo y las fases previamente descritas se pueden apreciar en la figura 3.7, siendo los 2 trapecios en la izquierda los codificadores, en el medio el GRU bidireccional y el trapecio a la derecha el decodificador [3].

3.2.3. SVM: An Intelligent Diagnosis Method of Brain MRI Tumor Segmentation Using Deep Convolutional Neural Network and SVM Algorithm

Los autores proponen un modelo basado en la fusión de redes convolucionales profundas y algoritmos de máquinas de vectores de soporte (DCNN-F-SVM), con el objetivo de apoyar el diagnóstico y la segmentación de gliomas o tumores cerebrales sobre MRI. En la figura 3.8 se muestra el diagrama de flujo del modelo. El sistema comprende dos partes. La primera se basa es el preprocesado, extracción de características principales y entrenamiento de CNN y SVM. La otra parte se compone por las pruebas del modelo y la generación de la segmentación final [4].

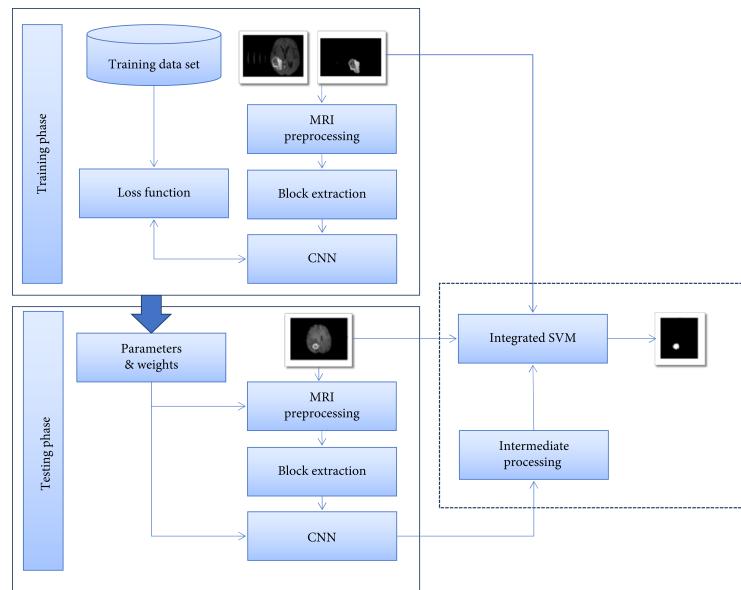


Figura 3.8: Diagrama del modelo [4].

En la primera fase se entrena los modelos CNN y SVM para obtener el mapeo de la imagen en escala de grises al dominio etiquetado del tumor. En la segunda etapa, la salida etiquetada de CNN y la imagen de prueba se ingresan en el clasificador SVM integrado. Por último, se utiliza una secuencia iterativa para conectar la CNN y el clasificador SVM integrado, lo cual aumenta el número de capas [4]. Para la selección de la característica óptima, se agrega un paso de procesamiento intermedio al modelo, tal como se ve en la figura 3.9

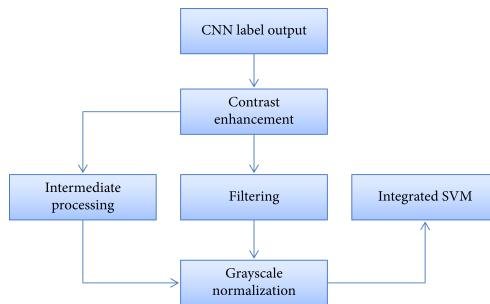


Figura 3.9: Diagrama esquemático de procesamiento intermedio [4].

Para la representación de cada pixel se usa la imagen en escala de grises, la media y la mediana. Estas características se utilizan para realizar el entrenamiento CNN y obtener un mapeo no lineal entre las características de entrada y las etiquetas. En la etapa de prueba, un clasificador SVM agregado se entrena de forma independiente utilizando el mapa de etiquetas CNN agregado y las mismas características del proceso anterior [4].

Un proceso iterativo de clasificación es aplicado a la imagen de entrada preprocesada. Primero, CNN clasifica los píxeles en el área clave, generando una especie de presegmentación que se envía al clasificador SVM. Luego, se genera una región de interés sobre la presegmentación y se hace una clasificación basada en SVM integrada en ese ROI. Después de eso, el SVM explora la vecindad de la salida del CNN. Usa CNN para clasificar nuevamente el ROI marcado y repite sobre los pasos para refinar los resultados de la segmentación [4].

3.2.4. Automatic MRI Segmentation of Para-pharyngeal Fat Pads Using Interactive Visual Feature Space Analysis for Classification

Los autores desarrollaron un algoritmo de segmentación automática basado en contexto para delinear la grasa parafaríngea. La metodología para esta segmentación consiste en que se extraen objetos gruesos como candidatos. Posteriormente, estos se analizan teniendo en cuenta sus valores característicos haciendo uso de una vista multidimensional de características. Luego, se usa un clasificador supervisado, el cual a su vez hace uso de una herramienta de análisis visual interactiva y finalmente se refina la forma [5].

En la figura 3.10 [5] se puede apreciar un pipe line en el que se evidencia el proceso que proponen los autores.

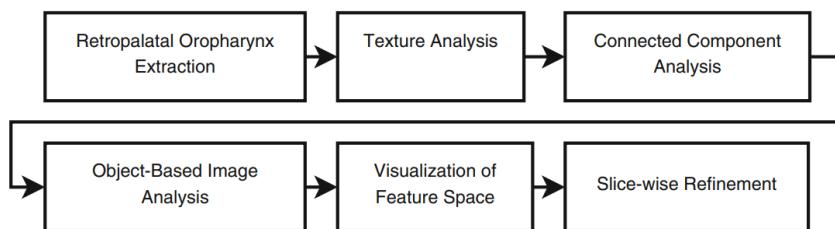


Figura 3.10: Pipe Line Propuesto en *Rahman et al.* [5]

Este algoritmo de segmentación fue probado en una selección aleatoria entre treinta conjuntos de datos, cada uno de estos conjuntos representan un sujeto. Adicionalmente, se tiene cada MRI con una resolución de $176 \times 256 \times 176$ vóxeles. Las métricas de calidad que se evaluaron fueron el coeficiente de DICE, volumen de fracción de verdaderos positivos (TPVF) y volumen de fracción de falsos positivos (FPVF) [5]. Como verdades base se tomaron 10 segmentaciones manuales seleccionadas al azar por dos observadores bajo supervisión de un radiólogo. Los resultados de las métricas fueron [5]:

- DICE: 0,779
- TPVF: 0,791
- FPVF: 0,241

Adicionalmente, se comparó el algoritmo propuesto contra los algoritmos de segmentación tradicionales, los resultados de dicha comparación se encuentran en la tabla 3.5.

Algoritmos	DICE (%)	TPVF (%)	FPVF (%)
Algortimo del artículo Prom.	77.9	79.1	24.1
Region Growing Prom.	35.8	46.9	181.8
Fuzzyc-means Prom.	43.4	52.3	92.1
MultiOtsu Prom.	39.8	71.6	226.4
Watersheds Prom.	28.6	19.8	10.8
Level Sets Prom.	40.0	43.8	68.3

Tabla 3.5: Comparación del Algoritmo de *Rahman et al.* [5] y los Algoritmos Tradicionales.

3.2.5. Comparación del Desempeño

Dados los trabajos relacionados expuestos anteriormente, se presenta la tabla 3.6 donde aparece la métrica Dice Score que permite identificar la similitud de las segmentaciones predichas por el algoritmo y las reales. Esta métrica se aplica sobre las redes convolucionales (CNN), las redes recurrentes (RNN), la máquina de vectores de soporte (SVM) y el algoritmo propuesto en *Rahman et al.* [5]. Evidentemente, estos resultados no son equivalentes, sin embargo, revelan cuáles de estas soluciones pueden dar mejores resultados.

	CNN	RNN	SVM	Algortimo <i>Rahman et al.</i>
DICE Prom.	0.93	0.89	0.87	0.78

Tabla 3.6: Comparación de trabajos relacionados.

3.3. Oportunidad

Como se puede evidenciar en el presente capítulo, el SAHOS es una patología cuyo diagnóstico se dificulta dado que su sintomatología es inespecífica, por lo que diagnóstico es costoso. Sin embargo, reciente evidencia parece indicar que existe una correlación entre el colapso de la vía aérea y el tejido adiposo en el espacio parafaríngeo. No obstante, las investigaciones realizadas no han obtenido evidencia contundente a causa de sus bajos intervalos de confianza. El principal motivo de que dichos intervalos no sean concluyentes es la escasez de datos. Esta es causada por los altos costos en los que se incurren para obtener segmentaciones de imágenes médicas cuya calidad satisfaga el nivel de rigurosidad

de los estudios. Dicho esto, es evidente que existe una oportunidad en el desarrollo de herramientas que faciliten el trabajo de los investigadores.

Adicionalmente, tal como se evidencia en la sección de trabajos relacionados, se puede evidenciar que este proyecto no es la primera aproximación respecto a la problemática de los estudios del SAHOS. Sin embargo, la que se propone en este proyecto innova en este campo al hacer uso de aprendizaje profundo. De este modo, este proyecto también aprovecha la oportunidad de innovar en el campo de estudio del SAHOS.

Capítulo 4

Análisis del Problema

En el presente capítulo se resumen los resultados del proceso de análisis del problema. En dichos resultados se encuentran aspectos relevantes del problema como lo son los requerimientos, las restricciones y las especificaciones funcionales del sistema propuesto. El proceso y aspectos más detallados de este pueden ser encontrados en el anexo “Especificación de requerimientos”.

4.1. Contexto del Sistema

La figura 4.1 muestra un diagrama de contexto. Este fue realizado con el fin de entender el qué y el cómo el sistema se relaciona en función de lo que el usuario desea realizar.

Como se puede apreciar, el sistema tiene un solo actor que interactúa, siendo éste el usuario. Agregado a esto se puede identificar que el sistema está dividido en dos subsistemas, los cuales son el subsistema de entrenamiento y el subsistema de segmentación, en cuanto a las entradas del sistema se puede notar, que el usuario ingresa por texto la ruta de los recursos que se desean utilizar, con esta información cualquiera de los 2 subsistemas carga esos recursos. Finalmente, las salidas de este sistema varían entre los subsistemas, en el subsistema de entrenamiento la salida es un modelo entrenado y sus métricas de desempeño, por el lado del subsistema de segmentación la salida son las imágenes segmentadas.

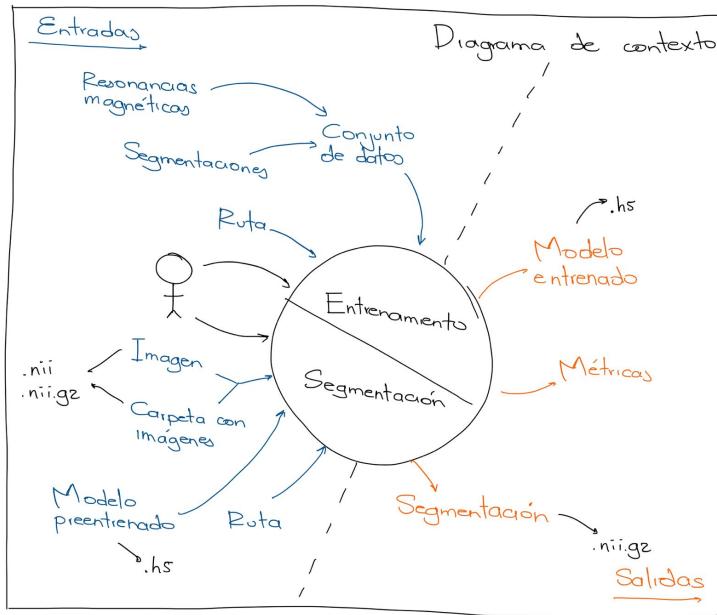


Figura 4.1: Diagrama de Contexto del Sistema.

4.2. Requerimientos

Los requerimientos del sistema están comprendidos en 2 categorías, funcionales y no funcionales.

4.2.1. Requerimientos Funcionales

En esta sección se encuentran los requerimientos funcionales del sistema, los cuales se caracterizan por describir el comportamiento y/o funcionalidad de un sistema, subsistema y módulo.

Para identificar estos requerimientos se optó por agruparlos por la tarea que desempeña en el sistema, posteriormente se sub-agruparon dependiendo en cuál de los subsistemas ejerce dicha tarea.

■ Carga de Datos:

Los requerimientos en esta categoría se encargan principalmente de cargar datos y

recursos digitales en el sistema, esto con el fin de que puedan ser utilizados en otras funcionalidades.

- **Subsistemas de Entrenamiento y Segmentación:**

- **RF-1:** Cargar Imágenes.

- **Subsistema de Segmentación:**

- **RF-2:** Cargar Modelo.

- **Preprocesamiento de Datos:**

El requerimiento en esta categoría se encarga principalmente de preparar los datos cargados en el sistema, esto con el fin de que puedan ser utilizadas en las funcionalidades posteriores de la ejecución.

- **Subsistemas de Entrenamiento y Segmentación:**

- **RF-3:** Preprocesar Imágenes.

- **Entrenamiento:**

Los requerimientos de esta categoría se encargan de entrenar y evaluar el modelo generado por el conjunto de datos dados por el usuario.

- **RF-4:** Entrenar Modelo.

- **RF-5:** Evaluar Modelo.

- **Segmentar:**

El requerimiento en esta categoría se encarga de hacer uso de los datos dados por el usuario (imágenes y modelo entrenado) para generar una salida deseada por el usuario (segmentaciones).

- **RF-6:** Segmentar Imágenes

- **Persistir:**

Los requerimientos en esta categoría se encargan principalmente de guardar en el sistema de archivos del computador los resultados generados de procesar los datos.

- **Subsistema de entrenamiento:**

- **RF-7:** Guardar Modelo.

- **Subsistema de segmentación:**

- **RF-8:** Guardar Segmentaciones.

■ **Interacción:**

Los requerimientos en esta categoría se encargan principalmente de la interacción que el usuario tiene con el sistema y viceversa.

● **Subsistemas de entrenamiento y segmentación:**

- **RF-9:** Acciones por Comandos.

4.2.2. Requerimientos No Funcionales

Para identificar y definir los requerimientos no funcionales se optó por basarse en el estándar de atributos de calidad ISO 25010. Para listar los requerimientos se identifica el atributo de calidad, seguido de un subatributo y finalmente el/los requerimiento/s funcionales asociados.

Adecuación Funcional

Representa la capacidad del producto software para proporcionar funciones que satisfacen las necesidades declaradas e implícitas cuando el producto se usa en las condiciones especificadas.

Completitud Funcional: Grado en el cual el conjunto de funcionalidades cubre todas las tareas y los objetivos del usuario especificados.

- **RNF-1:** El sistema implementa el 100 % de los casos de uso identificados.

Exactitud Funcional: Capacidad del producto o sistema para proveer resultados correctos con el nivel de precisión requerido.

- **RNF-2:** Los resultados de las segmentaciones realizadas por un modelo deben ser congruentes con la calidad y cantidad de los datos, así como los hiperparámetros usados para su entrenamiento.

Eficiencia/Desempeño

Esta característica representa el desempeño relativo a la cantidad de recursos utilizados bajo determinadas condiciones.

Comportamiento Temporal: Hace referencia tiempos de respuesta y procesamiento de un sistema cuando lleva a cabo sus funciones bajo condiciones determinadas en relación con un banco de pruebas (benchmark) establecido.

- **RNF-3:** El tiempo que requiere el sistema para segmentar una imagen debe ser inferior al que le toma a un experto el realizar la misma segmentación de forma manual.

Utilización de Recursos: Las cantidades y tipos de recursos utilizados cuando el software lleva a cabo su función bajo condiciones determinadas

- **RNF-4:** El sistema debe optimizar el uso de recursos como la memoria RAM y la memoria RAM dedicada de la GPU (VRAM) para que el entrenamiento de modelos se realice de forma satisfactoria.

Seguridad

Capacidad de protección de la información y los datos de manera que personas o sistemas no autorizados no puedan leerlos o modificarlos.

Integridad: Capacidad del sistema o componente para prevenir accesos o modificaciones no autorizados a datos o programas de ordenador.

- **RNF-5:** El sistema no debe realizar segmentaciones y/o modificaciones sobre los archivos originales, sea para los datos que se usen en entrenamiento o en segmentación.

4.3. Restricciones

En esta sección se detallan restricciones que se consideran relevantes para el diseño e implementación del sistema.

- **C-1:** El sistema funciona única y exclusivamente para resonancias magnéticas.

- **C-2:** El conjunto de datos utilizado para generar el modelo entrenado debe proceder de fuentes que garanticen la calidad de las imágenes.
- **C-3:** El conjunto de datos de entrenamiento debe incluir tanto las imágenes como las segmentaciones de la región de interés.
- **C-4:** El entrenamiento se hace por medio de técnicas de aprendizaje profundo (CNN).
- **C-5:** Las imágenes de entrada y los resultados de las segmentaciones generadas por el sistema deben poder ser visualizadas en cualquier software que se especialice en su visualización y/o manipulación (formato NIfTI).
- **C-6:** El sistema solo puede generar y cargar modelos de formato “Hierarchical Data Format” en su quinta versión (.h5).

4.4. Especificaciones Funcionales

Como resultado del proceso de identificar y relacionar los objetos de interés previamente expuestos, se obtuvieron los siguientes casos de uso:

- **CU-1:** Entrenar Modelo.
- **CU-2:** Segmentar Imágenes.

4.4.1. CU-1: Entrenar Modelo

Haciendo uso de un conjunto de datos ingresados por el usuario, el sistema debe hacer un preprocesado sobre esos datos, entrenar un modelo con esos datos y finalmente guardar el modelo resultado.

4.4.2. CU-2: Segmentar Imágenes

El sistema debe realizar y guardar las segmentaciones de un conjunto de imágenes dadas por el usuario haciendo uso de un modelo previamente entrenado.

4.4.3. Diagrama de casos de Uso

El diagrama correspondiente a los casos de uso anteriormente expuestos se encuentra en la figura 4.2. Como se puede apreciar, el actor hace uso de los casos “Entrenar Modelo” y “Segmentar Imágenes”.

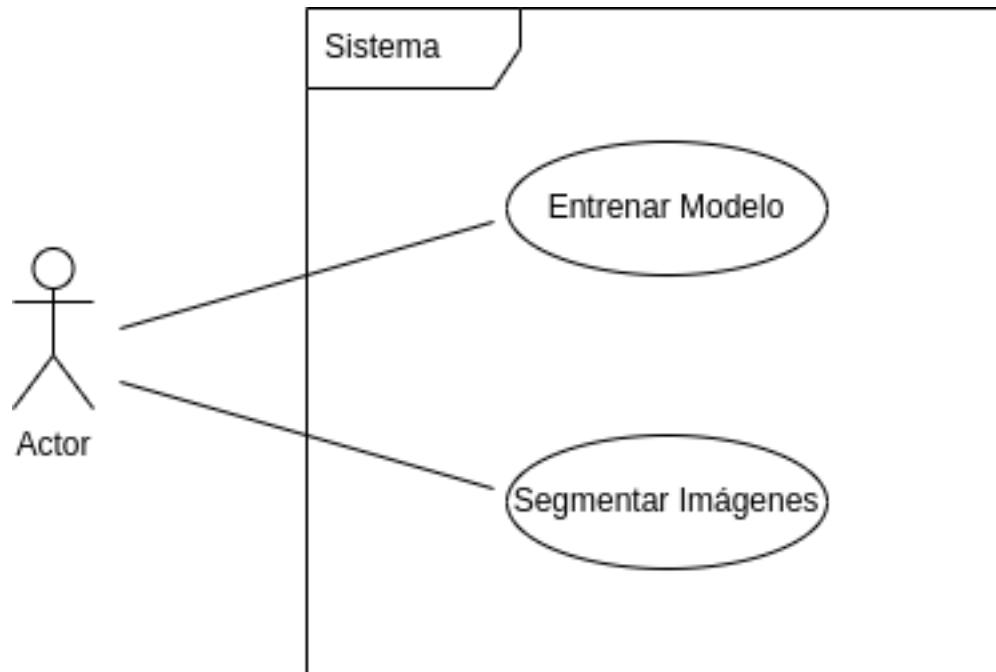


Figura 4.2: Diagrama de Casos de Uso del Sistema.

4.5. Priorización

Dado el alcance y las características del proyecto, se desarrolló un método propio de priorización basado jerarquización por niveles de abstracción y un análisis bidimensional. El proceso completo y aspectos más detallados del método pueden ser encontrados en el documento anexo “Especificación de Requisitos”.

El resultado de dicho método puede ser apreciado en la tabla 4.1.

ID	Descripción del driver
RNF-1	El sistema implementa el 100 % de los casos de uso identificados.
CU-1	Entrenar Modelo
CU-2	Segmentar Imágenes.
RF-9	Acciones por Comandos.
RF-1	Cargar Imágenes.
RF-4	Entrenar Modelo.
RF-7	Guardar Modelo.
RNF-4	El sistema debe optimizar el uso de recursos como la memoria RAM y la memoria RAM dedicada de la GPU (VRAM) para que el entrenamiento de modelos se realice de forma satisfactoria.
RF-2	Cargar Modelo.
RF-6	Segmentar Imágenes.
RF-8	Guardar Segmentaciones.
C-5	Las imágenes de entrada y los resultados de las segmentaciones generadas por el sistema deben poder ser visualizadas en cualquier software que se especialice en su visualización y/o manipulación (formato NIFTI).
C-4	El entrenamiento se hace por medio de técnicas de aprendizaje profundo (CNN).
RF-5	Evaluuar Modelo.
C-6	El sistema solo puede generar y cargar modelos de formato “Hierarchical Data Format” en su quinta versión (.h5).
RF-3	Preprocesar Imágenes.
Nota-1	Los requerimientos no funcionales RNF-2 y RNF-3 fueron excluidos de esta priorización, esto dado que si bien son factores determinantes de la calidad del sistema, su naturaleza es de carácter experimental, por ello las estrategias para satisfacerlos se abordan en el plan de pruebas del sistema y en la ejecución del mismo.
Nota-2	El requerimiento no funcional RNF-5 no está listado en la priorización, ya que pertenece a la categoría de atributos de calidad seguridad y a la subcategoría integridad. Teniendo en cuenta su descripción y las características en común de los elementos priorizados (Datos), se toma como un requerimiento asociado al sistema en todos sus niveles de abstracción y jerarquización.
Nota-3	La restricción C-2 no será abordada, dado que el mantener control sobre dichos recurso es algo que se escapa del alcance y naturaleza de este proyecto.

Tabla 4.1: Drivers Arquitectónicos Priorizados.

Capítulo 5

Diseño de la Solución

En este capítulo se resume de la metodología de diseño utilizada y el resultado final de aplicar dicha metodología. El proceso y aspectos más detallados de los resultados pueden ser encontrados en el anexo “Documento de Arquitectura de Software”.

5.1. Metodología

Para el diseño del sistema se seleccionó el método ADD (Attribute Driven Design).

ADD es un método para definir una arquitectura de software en la cual el proceso de software está basado en los requisitos de los atributos de calidad de software. Este método sigue un proceso de diseño recursivo para descomponer los elementos o un sistema en sí, aplicando tácticas arquitecturales y patrones que satisfagan los drivers [32].

ADD es método que está compuesto por los siguientes pasos:

1. **Validación de entradas:** Este paso suele hacerse una sola vez que el equipo de diseño determina que tiene la suficiente información, requerimientos y otros drivers arquitectónicos para realizar el proceso de diseño.
2. **Selección de elemento del sistema a descomponer:** En este paso se selecciona el elemento del sistema que se va a descomponer.
3. **Identificar el driver arquitectónico candidato:** Se selecciona el driver o los drivers arquitectónicos (usualmente este paso está asociado a la priorización de requerimientos y drivers).

4. **Selección de concepto de diseño:** En este paso se seleccionan conceptos de diseño de software que puedan satisfacer el driver o los drivers previamente seleccionados.
5. **Instanciación de elementos:** En este paso son instanciados los elementos de resultado del paso previo, y se les asignan responsabilidades.
6. **Definir interfaces:** En este paso se definen interfaces para los elementos previamente instanciados.
7. **Verificación y refinamiento:** En este paso se refinan los requerimientos y se vuelven restricciones para los elementos instanciados.
8. **Repetir:** Se repiten los pasos del 2 al 7 las veces que sean necesarias para satisfacer los drivers del sistema.

5.2. Arquitectura de la Solución

En la presente sección se muestra la arquitectura de la solución, esta se encuentra representada en 5 vistas, 4 de estas realizadas basándose en el modelo 4+1, y siendo la quinta de estas una representación de la red neuronal propuesta.

5.2.1. Vista Lógica

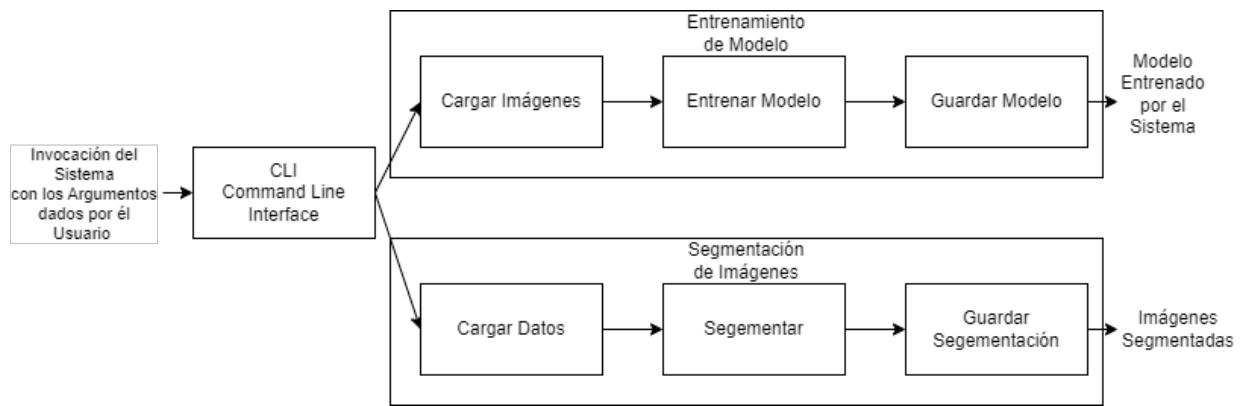


Figura 5.1: Vista Lógica del Sistema

En la figura 5.1 se puede apreciar la vista lógica del sistema, esta expresa la estructura funcional del sistema. Adicionalmente, en esta se pueden observar 2 aspectos relevantes del sistema. Primero, el patrón/estilo arquitectónico del sistema es Pipes and Filters (Tubos y filtros), esto indicándonos que es un sistema centrado en el flujo y procesamiento de datos. Segundo, el sistema en su nivel más alto de abstracción está compuesto por 2 subsistemas y una interfaz por línea de comando, por la cual el usuario interactúa con el sistema. A su vez, los subsistemas internamente están compuestos por unidades funcionales más pequeñas y específicas, conocidas como componentes, dichos componentes tienen responsabilidades asociadas que cuando se realizan en conjunto y en el orden correcto generan el resultado deseado.

5.2.2. Vista de Procesos

En la figura 5.2 se aprecia la vista de procesos del sistema, a pesar de ser sencilla, denota con gran fidelidad el ciclo de vida del realizar una ejecución del sistema. Adicionalmente, se aprecia que es posible realizar múltiples ejecuciones de sistema en simultáneo, de este modo permitiendo a diferentes procesos contener dichas ejecuciones.

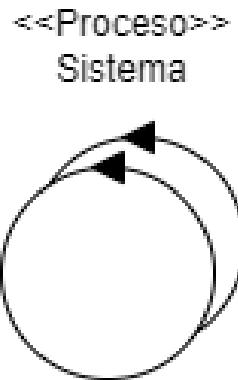


Figura 5.2: Vista de Procesos del Sistema

5.2.3. Vista de Implementación

En la figura 5.3 se encuentra la vista de implementación del sistema, en esta se puede ver principalmente donde se ubican los elementos del sistema y como se relacionan entre sí.

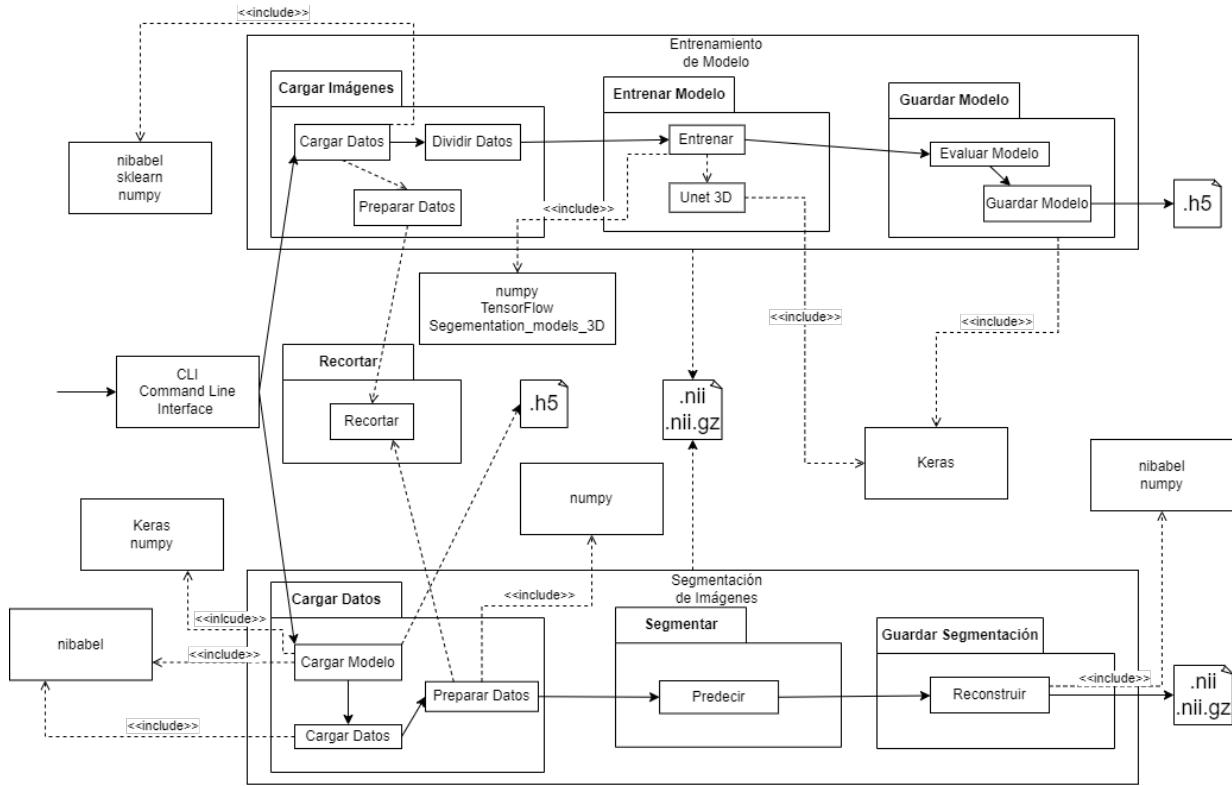


Figura 5.3: Vista de Implementación del Sistema

Se aprecia a simple vista la gran cantidad de decisiones que fueron tomadas en esta vista, dichas decisiones abarcaron la descomposición de los componentes identificados en la vista lógica en unidades funcionales más pequeñas denominadas módulos, el determinar y diferenciar las relaciones presentes en los elementos del sistema y la selección de librerías y tecnologías a usar en el desarrollo.

5.2.4. Vista Física

En la figura 5.4 se encuentra la vista física del sistema, esta representa el mapeo de donde se aloja y ejecuta el software en el hardware, entre otras características como puertos, protocolos de comunicación entre dispositivos y otros, dado el alcance y objetivo de estas últimas no son relevantes, sin embargo, pueden ser características deseables en trabajos futuros.

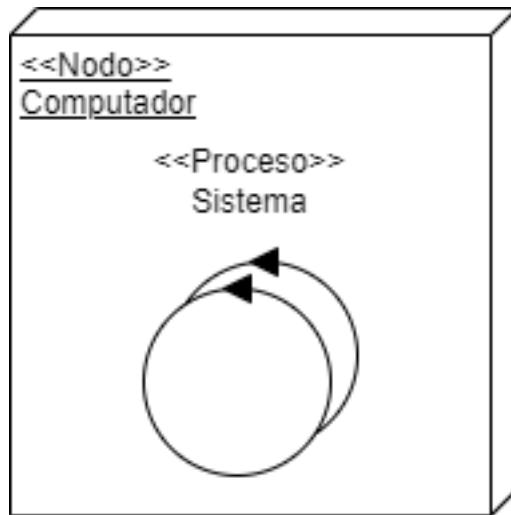


Figura 5.4: Vista de Física del Sistema

Un aspecto importante a notar sobre esta vista es la relevancia de las especificaciones del dispositivo donde el sistema sea ejecutado y la función del sistema de la que se haga uso, dado que la funcionalidad de entrenamiento puede llegar a consumir una cantidad significativa de recursos computacionales, esto afecta directamente la cantidad de procesos de ejecución del sistema que pueden funcionar simultáneamente, adicionalmente dependiendo de las especificaciones del dispositivo y el volumen de datos a ser procesado es posible que no se puedan llegar a ejecutar funcionalidades del sistema.

5.2.5. Vista de Arquitectura de Red Neuronal

Teniendo en cuenta las vistas anteriormente mencionadas y en pro de cumplir con los requerimientos del sistema, así como con sus restricciones, se hicieron decisiones relevantes que ayudaron a una óptima construcción de la arquitectura de la red neuronal convolucional presentada en la imagen 5.5. Esta arquitectura se divide en dos partes:

- **Trayectoria de contracción:** Utilizada para capturar el contexto en la imagen; tanto la región de interés como sus demás partes.
- **Trayectoria de expansión:** Utilizada para permitir una localización precisa, en este caso de la región de interés, mediante convoluciones transpuestas.

El número de convoluciones usadas en las capas de las trayectorias fue decidido con el propósito de abarcar la mayor información de la imagen en las primeras capas, optimizando el uso de los recursos, para realizar filtros de mayor calidad (a lo largo de las trayectorias) que ayudaron a una identificación exitosa de la región de interés en la imagen.

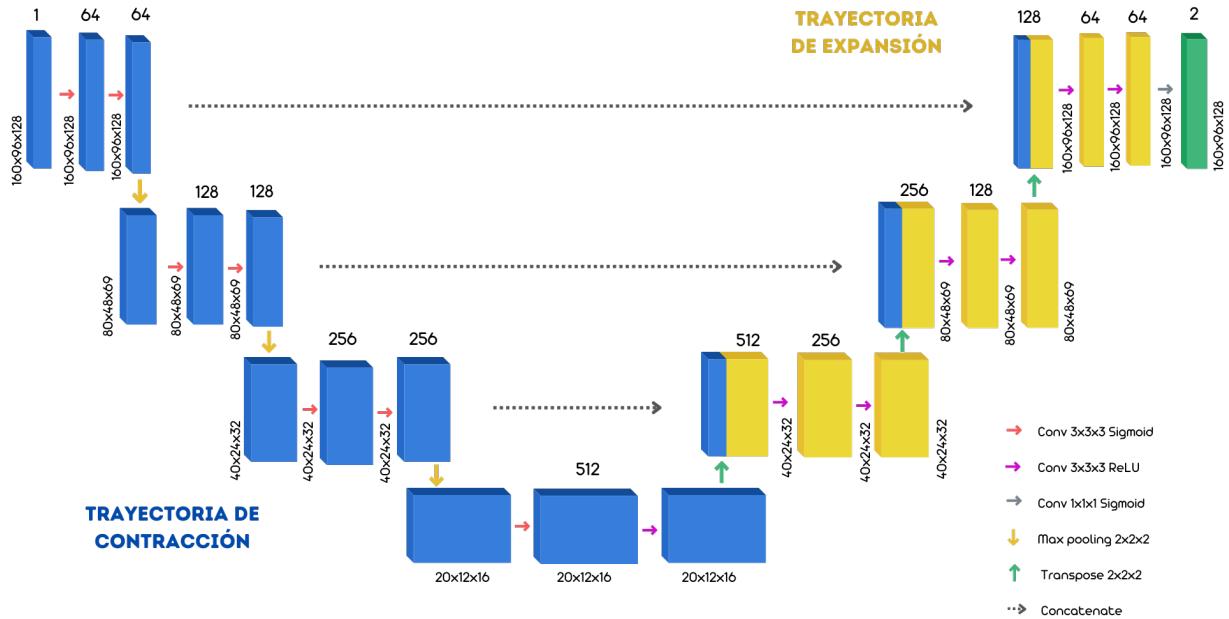


Figura 5.5: Arquitectura de Red Neuronal Convolucional.

Información más detallada de la arquitectura y su funcionamiento se encuentra en el anexo “Documento de Arquitectura de Software”.

Capítulo 6

Implementación de la Solución

En este capítulo se detalla como se llevaron a cabo las fases metodológicas descritas en el plan de proyecto, en cada una de estas fases se relacionan las actividades planificadas y los resultados obtenidos después de su ejecución. Al final se enseña el resultado del trabajo llevado a cabo a lo largo de este proyecto, el producto final, allí se describen las características generales y como se puede instalar y hacer uso del producto.

6.1. Fases Metodológicas

En esta sección se detalla el proceso y las decisiones que se tomaron para la gestión de cada fase metodológica. Aunque se presentaron algunas alteraciones en el proyecto, en esencia se cumple con la mayoría de las actividades planeadas y los requerimientos de las metodologías adaptadas.

A lo largo del ciclo de vida del proyecto se aplicaron algunos artefactos y eventos de la metodología Scrum. Semanalmente, se organizaron reuniones con el director para, revisar los resultados obtenidos durante la semana y realizar el reconocimiento de los objetivos y tareas de la siguiente iteración, al final de esta reunión se hace una retroalimentación y revisión del estado del equipo y del proyecto, aunque no se realizaron las reuniones diarias debido a las restricciones de tiempo y disponibilidad del equipo, la interacción se mantuvo constante y no supero 3 días sin interacción y comunicación entre miembros.

Nota: En el plan de proyecto se ofrece mayor información de las fases y los objetivos de las actividades. Además, En las últimas páginas de ese documento se describen algunas circunstancias que surgieron durante el ciclo de vida del proyecto y como se gestionaron.

6.1.1. Fase I: Recopilación de recursos

Durante la ejecución de esta etapa se define: la relevancia de los recursos, cuáles deben empezarse a buscar y cuáles dejaron de ser importantes para el proyecto. La interacción constante por parte de los miembros del equipo fue indispensable para mantener los objetivos del proyecto alineados y velar por la consistencia de la investigación, si surgía un aporte significativo con la capacidad de alterar el diseño de la solución o los objetivos de las actividades, se debía actualizar la documentación asociada e informar al equipo lo más pronto posible.

Las actividades planeadas y los resultados objetivos son listados a continuación. En la actividad de búsqueda de fuentes se dividieron las tareas por temas y campos de conocimiento, por ejemplo, algunos miembros se enfocaron en buscar fuentes relacionadas a tipos de segmentaciones automáticas, otros en métricas, otros en imágenes médicas, etc. Esta actividad se realizó de esta manera para especializar a los miembros en las áreas más afines con sus responsabilidades y competencias.

Búsqueda de fuentes:

- Filtrado y categorización por grado de relevancia y tema.
- Construcción de un conjunto de fuentes sólidas, relevantes y suficientes para realizar la documentación de la investigación.

Consulta de expertos:

- Consulta de un especialista en arquitectura de software para enriquecer y complementar el diseño de la solución, fase previa a la recopilación.
- Consulta de un especialista en aprendizaje profundo para la configuración de los hiperparámetros de la red neuronal utilizada. Esta tarea se hace durante el diseño de la solución, pero hace parte de esta fase.

Recolección de otros recursos:

- Obtención del conjunto de datos (imágenes de resonancias magnéticas) con ayuda de la facultad de medicina y el hospital San Ignacio.

Búsqueda de un modelo:

- Análisis de diferentes arquitecturas de redes neuronales para segmentación de resonancias magnéticas en 3D.
- Evaluación y selección de los modelos obtenidos.

Documentación

- Redacción de los capítulos relacionados con la contextualización del entorno, la definición del problema y la solución propuesta, con base en la investigación realizada.

Las actividades relacionadas con investigación, estructuración de la información y documentación fueron evolucionando continuamente, la ejecución de iteraciones sobre estas se detuvo junto con el diseño de la solución. Claramente, a medida que la solución fue madurando las modificaciones fueron cada vez más sutiles, estas iteraciones se realizaron para conseguir que la base del conocimiento y el entorno permanezcan alineadas con el diseño de la solución.

6.1.2. Fase II: Diseño

Utilizar la metodología basada en diseño definitivamente fue provechoso para esta fase. aunque es una metodología que toma algo de tiempo, debido al cambio continuo por la interacción entre el diseño, el entorno y la base del conocimiento, los resultados tanto del proceso del diseño como de la estructuración y priorización de sus elementos y su respectiva documentación fueron satisfactorios.

Como se define en el plan de proyecto, esta fase se divide en tres sub-fases, estas se dividen en actividades y a su vez las actividades en tareas más pequeñas. En resumen, en esta fase se identificaron los elementos de diseño: casos de uso, restricciones y requisitos del sistema, con la ayuda diferentes herramientas, se hizo la categorización y priorización de los elementos de diseño, se iteró sobre ellos aplicando diferentes tácticas, se construyó la arquitectura del sistema y finalmente se documentó todo el proceso de la fase de diseño.

Especificación de elementos de diseño:

- Especificación de restricciones, requisitos y casos de uso.
- Elaboración del diagrama de contexto y el diagrama de casos de uso.

Priorización de requisitos:

- Construcción de un método de priorización.
- Priorización de los elementos de diseño.

Diseño de la arquitectura:

- Ejecución de la metodología ADD para el diseño de la arquitectura.

Documentación:

- Documentación de las herramientas y métodos utilizados para la especificación y priorización de los elementos de diseño
- Documentación de la arquitectura final.

6.1.3. Fase III: Implementación

En la fase de implementación se dividieron las tareas según las habilidades de cada miembro, por ejemplo a la persona que se especializó en imágenes, se encargó de implementar la preparación de las imágenes, a la persona que dirigió el proceso de diseño del sistema y la arquitectura, creó los módulos y configuró todos los requerimientos, la persona especializada en aprendizaje máquina fue quien implementó y configuró la red neuronal.

Integración de tecnologías:

- Instalación y configuración de tecnologías para implementar la solución (Keras, Nibabel, Numpy, Segmentation Model 3d, Sklearn, TensorFlow, etc.).

Preparación de las imágenes:

- Implementación del algoritmo para redimensionar las imágenes.
- Implementación del algoritmo para la normalización de las imágenes.

Implementación de la red neuronal:

- Implementación de la red neuronal con ayuda de Keras.

Implementación de la CLI:

- Implementación y prueba de la interfaz de línea de comandos.

6.1.4. Fase IV: Validación

En este proyecto tal como la investigación se complementa con el diseño, la validación se complementa con la implementación, durante la fase de validación se llevó a cabo una documentación exhaustiva de cada prueba, tomando nota de la configuración y los parámetros de la red junto con el desempeño obtenido indicado por las métricas. Esto permite hacer un seguimiento general del comportamiento del producto y muestra cuáles son las características del sistema que se deben tratar para incrementar la calidad del sistema y alcanzar los objetivos del proyecto.

Evaluación de las funcionalidades del sistema:

- Se corrobora que tanto el modelo como las imágenes se están cargando en el sistema con éxito, y además las salidas son las esperadas.

Análisis de resultados:

- Cumplimiento de los objetivos relacionados con el desempeño del sistema a través de las métricas obtenidas.

6.2. Producto Final

En esta sección se muestran las funcionalidades del producto y como el usuario puede acceder y empezar a utilizarlo. Para empezar a utilizar el producto, el usuario solo debe descargar el recurso y ya puede empezar a interactuar con el sistema por medio de la interfaz de línea de comando. Para acceder al manual de uso integrado, el usuario debe ejecutar el comando “-h”, como se puede observar en la figura 6.1, el sistema muestra todos los comandos que el usuario puede ejecutar y cómo debe ingresarlos para poder hacer uso de las funcionalidades del sistema.

```
● takina@ZBook:~/Desktop/trabajo_grado-impl_v1/code/CLI$ python3 main.py -h
2022-11-12 12:10:54.494253: I tensorflow/core/platform/cpu_feature_guard.cc:193] This TensorFlow
actions in performance-critical operations: AVX2 FMA
To enable them in other operations, rebuild TensorFlow with the appropriate compiler flags.
2022-11-12 12:10:54.607539: E tensorflow/stream_executor/cuda/cuda_blas.cc:2981] Unable to register
2022-11-12 12:10:55.088986: W tensorflow/stream_executor/platform/default/dso_loader.cc:64] Could
e: No such file or directory; LD_LIBRARY_PATH: /usr/local/cuda-11.8/lib{LD_LIBRARY_PATH:+:/usr/loc
2022-11-12 12:10:55.089039: W tensorflow/stream_executor/platform/default/dso_loader.cc:64] Could
red object file: No such file or directory; LD_LIBRARY_PATH: /usr/local/cuda-11.8/lib{LD_LIBRARY_
2022-11-12 12:10:55.089045: W tensorflow/compiler/tf2tensorrt/utils/py_utils.cc:38] TF-TRT Warning:
make sure the missing libraries mentioned above are installed properly.
Segmentation Models: using `tf.keras` framework.
usage: main.py [-h] [-s SYSTEM] [-i INPUT] [-o OUTPUT] [-m MODEL] [-d DATASET] [-om OUTPUT_MODEL]

Initialize the system either to segment adipose tissue on the input image(s) (MRI) or to train a
options:
-h, --help           show this help message and exit
-s SYSTEM, --system SYSTEM
                   Initialize the system (segment or train)
-i INPUT, --input INPUT
                   Input image(s) path
-o OUTPUT, --output OUTPUT
                   Output image(s) path
-m MODEL, --model MODEL
                   Model path for prediction
-d DATASET, --dataset DATASET
                   Dataset path for training
-om OUTPUT_MODEL, --output-model OUTPUT_MODEL
                   Output model path
○ takina@ZBook:~/Desktop/trabajo_grado-impl_v1/code/CLI$ █
```

Figura 6.1: Manual de Uso Integrado.

El sistema, además de contar con la funcionalidad de realizar segmentaciones sobre una y varias resonancias magnéticas, también le permite al usuario entrenar su propio modelo. Como se muestra en la figura 6.2 el usuario debe utilizar el comando “-s” seguido de la acción que desea ejecutar, en este caso “train” seguido de esto el usuario debe utilizar el comando “-d” e indicar la ruta del fichero donde se encuentra el conjunto de datos. Este fichero debe contener dos carpetas adicionales con el nombre de “imgs” y “masks” las cuales tendrán las resonancias y las segmentaciones respectivamente.

Figura 6.2: Resultado del Entrenamiento

Finalmente, para hacer una segmentación, ya sea sobre una o varias imágenes, el usuario debe indicar el comando “-s” y la acción que desea ejecutar, en este caso “segment”, seguido a esto debe indicar el comando “-i” junto a la ruta ya sea de la imagen individual o de la carpeta con el total de imágenes que se quiere segmentar, tal y como se muestra en la figura 6.3. El archivo con la segmentación se guarda en una carpeta por defecto. Al terminar la segmentación se imprime la ruta en donde se guardaron las imágenes y lanza un par de ventanas indicando el índice de DICE y la Precisión.

```
takina@Book:~/Desktop/trabajo_grado-impl_v1/code/CLI$ python3 main.py -s segment -i data/imgs/sub-A026_ses-01_acq-highres_T1w.nii.gz
2022-11-12 16:33:14.085790: I tensorflow/core/platform/cpu_feature_guard.cc:193] This TensorFlow binary is optimized with oneAPI Deep N
tions: AVX2 FMA
To enable them in other operations, rebuild TensorFlow with the appropriate compiler flags.
2022-11-12 16:33:14.200749: E tensorflow/stream_executor/cuda/cuda_bias.cc:2981] Unable to register cuBLAS factory: Attempting to regis
2022-11-12 16:33:14.677407: W tensorflow/stream_executor/platform/default/dso_loader.cc:64] Could not load dynamic library 'libnvinfer.
RARY_PATH: /usr/local/cuda-11.8/lib{LD_LIBRARY_PATH:+:/usr/local/cuda-11.8/lib64{LD_LIBRARY_PATH:+:/usr/local/cuda-11.8/lib64{LD_LIBRA
/usr/local/cuda-11.8/lib64{LD_LIBRARY_PATH:+:}}}}}
2022-11-12 16:33:14.677465: W tensorflow/stream_executor/platform/default/dso_loader.cc:64] Could not load dynamic library 'libnvinfer_
factory; LD_LIBRARY_PATH: /usr/local/cuda-11.8/lib{LD_LIBRARY_PATH:+:/usr/local/cuda-11.8/lib64{LD_LIBRARY_PATH:+:/usr/local/cuda-11.8/
BRARY_PATH:+:/usr/local/cuda-11.8/lib64{LD_LIBRARY_PATH:+:}}}}}
2022-11-12 16:33:14.677472: W tensorflow/compiler/tf2tensorrt/utils/py_utils.cc:38] TF-TRT Warning: Cannot dlopen some TensorRT librari
ioned above are installed properly.
Segmentation Models: using 'tf.keras' framework.
Loading model...
2022-11-12 16:33:16.926113: I tensorflow/stream_executor/cuda/cuda_gpu_executor.cc:980] successful NUMA node read from SysFS had negati
2022-11-12 16:33:16.947769: I tensorflow/stream_executor/cuda/cuda_gpu_executor.cc:980] successful NUMA node read from SysFS had negati
2022-11-12 16:33:16.948021: I tensorflow/stream_executor/cuda/cuda_gpu_executor.cc:980] successful NUMA node read from SysFS had negati
2022-11-12 16:33:16.948395: I tensorflow/core/platform/cpu_feature_guard.cc:193] This TensorFlow binary is optimized with oneAPI Deep N
tions: AVX2 FMA
To enable them in other operations, rebuild TensorFlow with the appropriate compiler flags.
2022-11-12 16:33:16.948977: I tensorflow/stream_executor/cuda/cuda_gpu_executor.cc:980] successful NUMA node read from SysFS had negati
2022-11-12 16:33:16.949157: I tensorflow/stream_executor/cuda/cuda_gpu_executor.cc:980] successful NUMA node read from SysFS had negati
2022-11-12 16:33:16.949320: I tensorflow/stream_executor/cuda/cuda_gpu_executor.cc:980] successful NUMA node read from SysFS had negati
2022-11-12 16:33:17.309841: I tensorflow/stream_executor/cuda/cuda_gpu_executor.cc:980] successful NUMA node read from SysFS had negati
2022-11-12 16:33:17.310032: I tensorflow/stream_executor/cuda/cuda_gpu_executor.cc:980] successful NUMA node read from SysFS had negati
2022-11-12 16:33:17.310151: I tensorflow/stream_executor/cuda/cuda_gpu_executor.cc:980] successful NUMA node read from SysFS had negati
2022-11-12 16:33:17.310249: I tensorflow/core/common_runtime/gpu/gpu_device.cc:1616] Created device /job:localhost/replica:0/task:0/dev
: 0000:01:00.0, compute capability: 7.5
Model loaded
Loading data...
Image loaded
Preparing data...
Segmenting image...
2022-11-12 16:33:19.277191: I tensorflow/stream_executor/cuda/cuda_dnn.cc:384] Loaded cuDNN version 8600
1/1 [=====] - 4s 4s/step
Reconstructing image...
Segmented image saved at: segmentations/sub-A026_ses-01_acq-highres_T1w_seg.nii.gz
takina@Book:~/Desktop/trabajo_grado-impl_v1/code/CLI$
```

Figura 6.3: Resultado de la Segmentación

Opcionalmente, el usuario puede cargar un modelo de segmentación diferente al que está alojado en el sistema por defecto, ya sea uno entrenado por el mismo o uno externo y puede elegir la ubicación donde desea que se guarde la segmentación, esto en el caso de realizar una segmentación. En el caso del entrenamiento, si lo desea, podrá seleccionar la ruta en donde se va a almacenar el modelo. Todas estas acciones opcionales se pueden ejecutar con los comandos que aparecen en el manual de uso integrado.

Capítulo 7

Resultados

A lo largo del desarrollo del plan de pruebas, y siguiendo la metodología adoptada, se observó cómo los cambios propuestos en las características a ser probadas guiaron el camino hacia resultados satisfactorios del sistema propuesto. En ese sentido, se exponen los resultados de la configuración óptima de estos cambios en las funcionalidades del sistema que permitió tener un rendimiento completo y de calidad en todo el mismo usando 2 conjuntos de imágenes: conjunto de imágenes de tejido adiposo generado por el equipo y conjunto de imágenes BraTS 2020.

7.1. Funcionalidad de Entrenamiento

7.1.1. Tejido Adiposo en Espacio Parafaríngeo

Teniendo en cuenta el conjunto de imágenes generado por el equipo sobre el tejido adiposo en el espacio parafaríngeo, se procedió a validar el desempeño de la funcionalidad de entrenamiento del sistema con estos datos. Para el entrenamiento de este conjunto de imágenes se utilizaron 63 resonancias divididas en 50 imágenes para entrenamiento y 13 imágenes para validación.

De esa manera, después de 500 épocas que el algoritmo estuvo entrenando, se encontró la historia del coeficiente de DICE durante este entrenamiento expuesta en la imagen 7.1. En esta imagen se observa que el punto más alto del coeficiente lo obtuvo en la época 411 con un 80 % para validación y 89 % para entrenamiento.

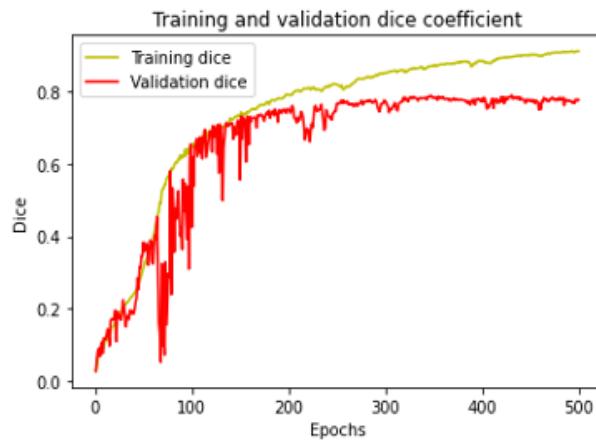


Figura 7.1: Coeficiente de DICE en Entrenamiento y Validación - Tejido Adiposo.

Asimismo, la imagen 7.2 muestra la precisión del algoritmo a lo largo de las 500 épocas, donde en la época 411 (mejor desempeño del algoritmo) se obtuvo una precisión del 99 % para validación y entrenamiento.

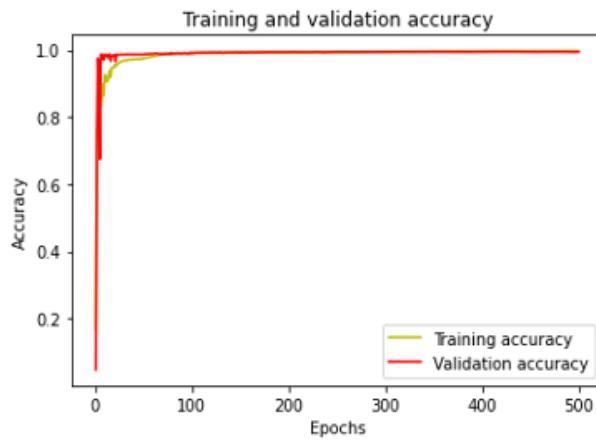


Figura 7.2: Precisión en Entrenamiento y Validación - Tejido Adiposo.

Además, se utilizó la función de pérdida *Dice Loss* para evaluar el algoritmo. Esta función optimiza las redes basándose en el coeficiente de DICE entre el resultado de la segmentación predicha y la segmentación real, por lo que puede aliviar eficazmente el desequilibrio entre la región de interés y el fondo [53]. Teniendo en cuenta esto, en la

Imagen 7.3 en la época 411 se obtuvo una pérdida de -14.64 en entrenamiento y -12.80 en validación.

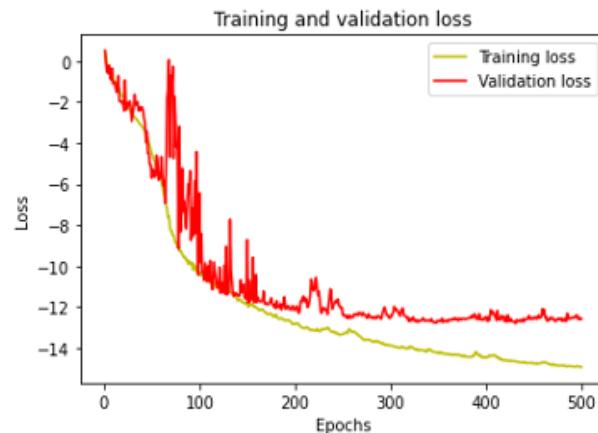


Figura 7.3: Pérdida en Entrenamiento y Validación - Tejido Adiposo.

Por último, se documentó este entrenamiento en la tabla 7.1 donde se muestran las características de las imágenes utilizadas, de la red neuronal, sus métricas mencionadas anteriormente y las características del recurso donde entrenó el modelo. En este caso, se explica con más detalle:

- Las dimensiones de las imágenes hacen referencia a alto, ancho y profundo respectivamente.
- Dado que las resonancias magnéticas utilizadas vienen en escala de grises, se utiliza 1 canal.
- Los pesos utilizados para las clases hacen referencia a que el algoritmo tenga más en cuenta una clase que otra. En este caso, la región segmentada tiene más peso que lo demás para que el algoritmo le ponga más atención.
- La arquitectura de 3D Unet mencionada en el capítulo 5.
- Aunque la pérdida dio negativa en el entrenamiento, para verificar la pérdida real de *Dice Loss* se utiliza la fórmula, $1 - DICE$ lo que resulta en una pérdida de 0.11 para entrenamiento y 0.20 para validación.

Intento 8		
Info image	No. imágenes	63 - 50 train, 13 test
	Dimensiones	(160,96,128)
	Canales	1
Info model	Pesos para clases	0: 0.5, 1: 34.5
	Arch unet	64*2 (sigmoid) - 128*2 (sigmoid)- 256*2 (sigmoid), 512 (sigmoid,relu), 256*2 (relu)- 128*2 (relu)- 64*2 (relu) - 2 (sigmoid)
	Optimizador	Adam
	Learning rate	0.00001
	Regularizador	No
Metrics	Epochas	500
	Dice	Train: 0.89 - Val: 0.80
	Accuracy	Train: 0.99 - Val: 0.99
	Tiempo	7hr:30min
Specs	Pérdida	Train: 0.11 - Val: 0.20
	GPU	Tesla V100-SXM2 16GB
	RAM	27GB
	Recurso	Colab Pro

Tabla 7.1: Intento con Mejor Resultado - Tejido Adiposo.

7.1.2. BraTS 2020

Asimismo, siguiendo con la validación de la funcionalidad de entrenamiento, se hizo uso del conjunto de imágenes por resonancia magnética del desafío BraTS 2020. BraTS 2020 utiliza imágenes de resonancia magnética preoperatorias multi-institucionales y se centra principalmente en la segmentación de tumores cerebrales intrínsecamente heterogéneos (en apariencia, forma e histología), es decir, gliomas [54].

Para el entrenamiento de este conjunto de imágenes se utilizaron 344 resonancias divididas en 274 imágenes para entrenamiento y 70 imágenes para validación. De esa manera, después de 175 épocas que el algoritmo estuvo entrenando, se encontró la historia del coeficiente de DICE durante este entrenamiento expuesta en la imagen 7.4. En esta imagen se observa que el punto más alto del coeficiente lo obtuvo en la época 125 con un 85 % para validación y 91 % para entrenamiento.

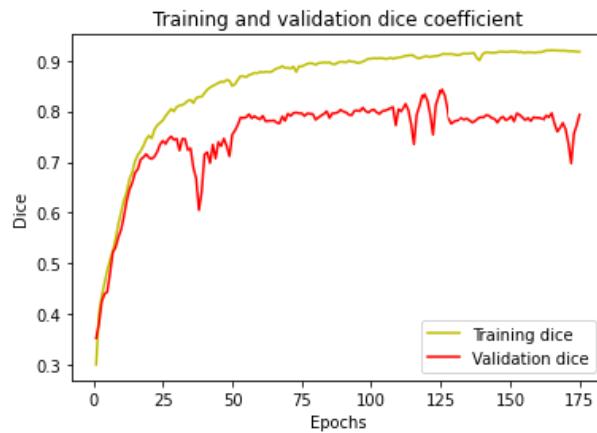


Figura 7.4: Coeficiente de DICE en Entrenamiento y Validación - BraTS 2020.

Asimismo, la imagen 7.5 muestra la precisión del algoritmo a lo largo de las 175 épocas, donde en la época 125 (mejor desempeño del algoritmo) se obtuvo una precisión del 98 % para validación y 99 % para entrenamiento.

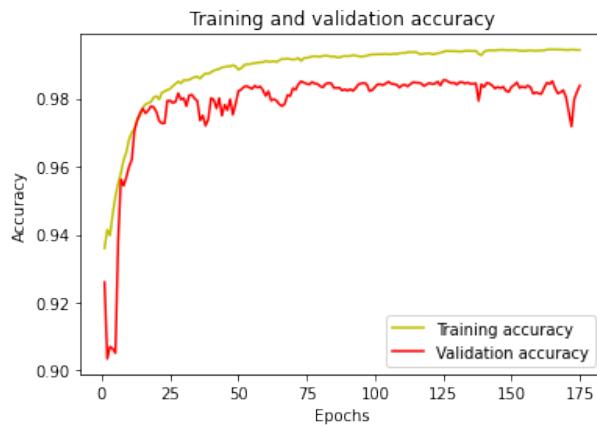


Figura 7.5: Precisión en Entrenamiento y Validación - BraTS 2020.

Además, se utilizó la función de pérdida *Categorical Focal Loss* para evaluar el algoritmo. Esta función de pérdida generaliza la entropía cruzada softmax multiclas introduciendo un hiperparámetro γ (gamma), llamado parámetro de enfoque, que permite que los ejemplos difíciles de clasificar sean penalizados más fuertemente en relación con los

ejemplos fáciles de clasificar [55]. En la imagen 7.6 se muestra la pérdida que obtuvo el algoritmo a lo largo de su entrenamiento, donde en la época 125 obtuvo una pérdida de 0.80 para validación y 0.77 para entrenamiento.

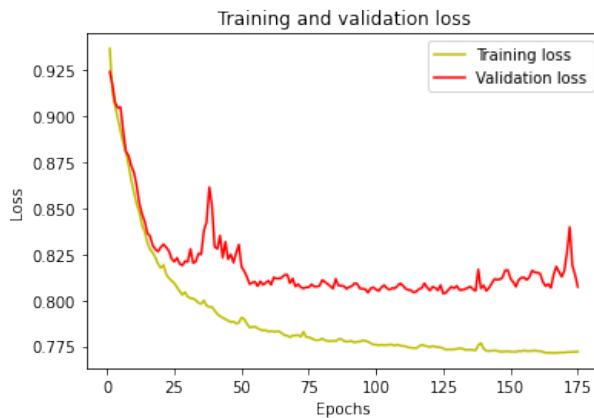


Figura 7.6: Pérdida en Entrenamiento y Validación - BraTS 2020.

Por último, se documentó este entrenamiento en la tabla 7.2 donde se muestran las características de las imágenes utilizadas, de la red neuronal, sus métricas mencionadas anteriormente y las características del recurso donde entrenó el modelo. En este caso, se explica con más detalle:

- Las dimensiones de las imágenes hacen referencia a alto, ancho y profundo respectivamente.
- Los canales de las imágenes son 3. Esto hace referencia a los 3 tipos de resonancias magnéticas utilizadas: FLAIR, T1CE y T2, permitiendo mayor recopilación de información del tumor.
- Los pesos iguales utilizados para las clases hacen referencia a que el algoritmo tenga en cuenta a las clases por igual.
- La arquitectura de 3D Unet mencionada en el capítulo anterior con excepción de que en la trayectoria de contracción se hizo uso de ReLU como función de activación.

Intento 5		
Info image	No. imágenes	344 - 274 train, 70 test
	Dimensiones	(128,128,128)
	Canales	3
Info model	Pesos para clases	0: 0.25, 1: 0.25, 2: 0.25, 3: 0.25
	Arch unet	64*2 (relu) - 128*2 (relu)- 256*2 (relu), 512 (relu), 256*2 (relu)- 128*2 (relu)- 64*2 (relu) - 4 (softmax)
	Optimizador	Adam
	Learning rate	0.00001
	Regularizador	No
	Epochas	175
Metrics	Dice	Train: 0.91 - Val: 0.85
	Accuracy	Train: 0.99 - Val: 0.98
	Tiempo	10hr:30min
	Pérdida	Train: 0.77 - Val: 0.80
Specs	GPU	A100 SXM4 40GB
	RAM	87GB
	Recurso	Colab Pro

Tabla 7.2: Intento con Mejor Resultado - BraTS.

7.2. Funcionalidad de Segmentación

Siendo esta funcionalidad la principal en el sistema propuesto, la variedad de pruebas, principalmente en la arquitectura de la red neuronal convolucional, ayudó a encontrar la configuración óptima de hiperparámetros, mostrada en las tablas anteriores para cada conjunto de imágenes, que obtuvo los mejores resultados en el entrenamiento para una segmentación de calidad para los dos conjuntos de imágenes utilizados. Estas segmentaciones tanto para el conjunto de imágenes del tejido adiposo como para el conjunto de imágenes de BraTS 2020 tuvieron un rango de 1 a 2 minutos en ser realizadas por el algoritmo.

7.2.1. Tejido Adiposo en Espacio Parafaríngeo

Teniendo en cuenta el resultado del mejor intento, se procedió a hacer la validación de la segmentación con las imágenes del conjunto de imágenes que fueron dispuestas para esta fase. De ese modo, en la imagen 7.7 se muestra la segmentación, en las distintas vistas de la resonancia magnética, del tejido adiposo en el espacio parafaríngeo que resultó del sistema con una imagen tomada de las imágenes de validaciones y se comparó con la segmentación hecha por el equipo de trabajo mostrada en la imagen 7.8.

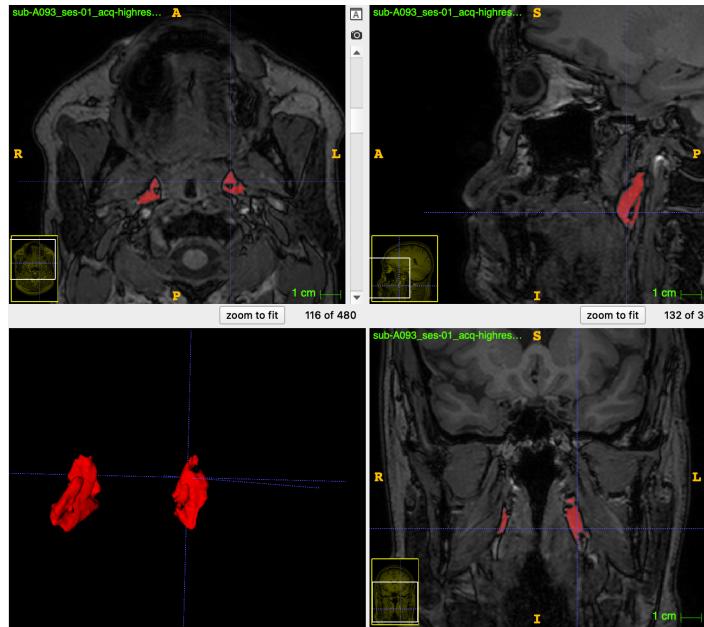


Figura 7.7: Segmentación Realizada por el Algoritmo.

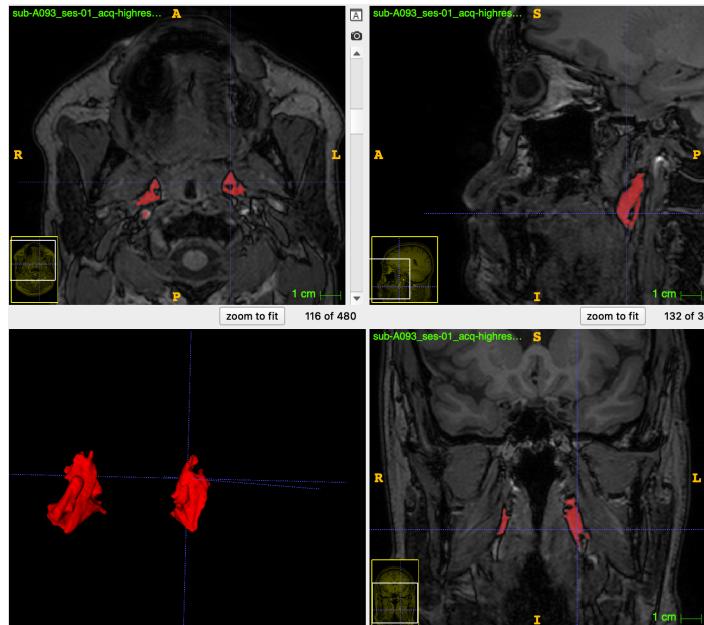


Figura 7.8: Segmentación Realizada por el Equipo.

7.2.2. BraTS 2020

Asimismo, para validar la segmentación como resultado del entrenamiento en el conjunto de BraTS teniendo en cuenta su coeficiente de DICE, se hizo uso de una resonancia tomada de las imágenes de validaciones y se comparó con la segmentación base de esa resonancia. En la imagen 7.9 se muestra un ejemplo de la segmentación predicha por el algoritmo. Se muestra de izquierda a derecha en el siguiente orden: la resonancia magnética del cerebro y su tumor, la segmentación base y la segmentación hecha por el algoritmo.

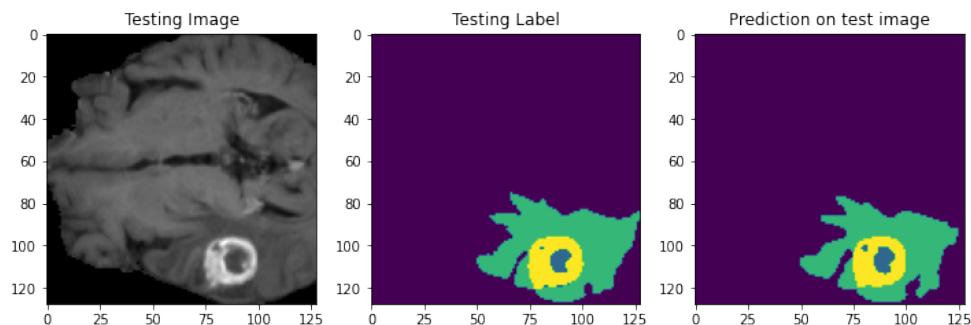


Figura 7.9: Validación Segmentación en BraTS.

7.3. Análisis de Resultados

7.3.1. Tejido Adiposo en Espacio Parafaríngeo

Teniendo en cuenta la calidad de las segmentaciones realizadas por el equipo, donde faltó criterio médico profesional para validar las segmentaciones hechas, se pudo observar que el modelo pudo sobresalir y obtener una segmentación satisfactoria e incluso mejor que la segmentación hecha por el equipo (basándose en el criterio y observación no experta del equipo). Su configuración óptima en los hiperparámetros, como por ejemplo los pesos asignados inicialmente (0.5 para el fondo y 34.5 para el tejido) para manejar el desbalance de datos, logró que el modelo tuviera un desempeño exitoso. Su rendimiento en la pérdida llegando casi a 0, junto con el coeficiente de DICE en un nivel del 80 %, indica que el modelo puede detectar con facilidad la región de interés, dando como resultado una segmentación exitosa.

7.3.2. BraTS 2020

Teniendo en cuenta el desempeño de la pérdida en el modelo, una posible razón de una pérdida “baja” se debe al peso de las clases. En este caso, todas las clases de la segmentación base (4) tuvieron el mismo peso (0.25). Esta asignación de pesos no tuvo en cuenta el manejo del desbalance de datos, lo que no permitió tener una mejor pérdida. Sin embargo, con el coeficiente de DICE en un nivel de 85 % se logra contrarrestar esta pérdida, permitiendo así un resultado de calidad. A este resultado también se le suma el uso de los 3 tipos de resonancias magnéticas: FLAIR, T1CE y T2, permitiendo mayor recopilación de información del tumor y llevando a una segmentación exitosa de este.

Capítulo 8

Conclusiones

Luego de todo el trabajo realizado, en esta sección se expone el análisis del impacto del proyecto tanto en la carrera de Ingeniería de Sistemas como en ámbitos sociales y educativos. Asimismo, se exponen las conclusiones del proyecto junto con el trabajo que se puede realizar a futuro.

8.1. Análisis de Impacto

Una de las intenciones de este proyecto es motivar a las personas interesadas en Ingeniería de Sistemas a desarrollar trabajos relacionados con la inteligencia artificial y la medicina. Teniendo en cuenta los resultados de este proyecto, se ve cómo la inteligencia artificial ha venido ganando importancia para apoyar varios procesos médicos que se pueden automatizar con el fin de ayudar a la comunidad médica y a las personas dependientes de esta. En ese sentido, se pretende incentivar a las universidades incluir en sus carreras, no solamente en Ingeniería de Sistemas, materias relacionadas con la inteligencia artificial para apoyar cualquier trabajo en el cual el/la estudiante quiera profundizar.

Asimismo, desde un punto de vista social, se pretende apoyar, a corto plazo, al experto médico en la tarea de segmentar cualquier región de interés en el cuerpo con el propósito de detectar algún tipo de anomalía o problema en esta región, permitiéndole utilizar este tiempo extra para poder enfocarse en otras tareas más importantes como el diagnóstico y tratamiento del problema. De ese modo, a mediano y largo plazo, se podría llegar a construir un sistema más completo y amigable con la comunidad médica donde se puedan utilizar no solo imágenes por resonancia magnética, sino otros tipos de imágenes médicas como tomografías computarizadas, entre otras.

8.2. Conclusiones y Trabajo Futuro

Teniendo en cuenta los resultados de este proyecto, aunque el modelo de tejido adiposo no pudo obtener el mínimo coeficiente de DICE objetivo, estuvo muy cerca de alcanzarlo. Sin embargo, teniendo en cuenta el desempeño que obtuvo el conjunto de datos de BraTS 2020, se pudo concluir que la principal razón que lleva a un coeficiente de DICE alto es la calidad de las imágenes. Por lo tanto, al no tener imágenes avaladas por expertos médicos, se tuvo complicaciones a la hora de alcanzar el DICE propuesto. No obstante, se puede observar que el rendimiento del sistema es de alta calidad, validando así el objetivo general de este trabajo de grado. Se pudieron obtener desempeños altos en los modelos entrenados por el sistema para así obtener segmentaciones de calidad de las regiones de interés trabajadas.

De ese modo, retomando la pregunta planteada en el presente proyecto: **¿Puede una herramienta de segmentación semiautomática de imágenes médicas tener la suficiente calidad de segmentado y eficiencia para apoyar la investigación del SAHOS?** y analizando los resultados presentados anteriormente, se puede concluir que sí. El sistema propuesto pudo obtener la suficiente calidad de segmentación del tejido adiposo en el espacio parafaríngeo y ser eficaz en términos de tiempo, tomando de 1 a 2 minutos para completar la segmentación. De ese modo, el sistema propuesto puede apoyar la investigación del SAHOS optimizando el tiempo de segmentación y agilizando procesos vitales para encontrar hallazgos importantes y llegar a conclusiones que faciliten el diagnóstico de este trastorno.

Asimismo, los trabajos futuros que se pueden realizar con este sistema pueden ser:

- Complementarlo para generar un sistema más robusto que apoye, no solo la investigación del SAHOS, sino también la investigación de otras enfermedades o trastornos que se basen en la segmentación de alguna parte, o región de interés, del cuerpo.
- Implementar una interfaz gráfica, en la cual el usuario pueda visualizar de forma más amigable las segmentaciones y pueda interactuar con ellas.
- Implementación del sistema propuesto en la nube, con el fin de brindar sus funcionalidades a más investigadores.
- Optimizar y distribuir el sistema entre más dispositivos para agilizar y reducir los tiempos de entrenamiento.

Referencias

- [1] “Head and Neck - ClinicalKey.” [Online]. Available: <https://www-clinicalkey-es-ezproxy.javeriana.edu.co/#!/content/book/3-s2.0-B9780323680424000025>
- [2] “Apnea del sueño - Síntomas y causas - Mayo Clinic.” [Online]. Available: <https://www.mayoclinic.org/es-es/diseases-conditions/sleep-apnea/symptoms-causes/syc-20377631>
- [3] “[PDF] Bidirectional RNN-based Few Shot Learning for 3D Medical Image Segmentation.” [Online]. Available: https://www.researchgate.net/publication/346030367_Bidirectional_RNN-based_Few_Shot_Learning_for_3D_Medical_Image_Segmentation
- [4] W. Wu, D. Li, J. Du, X. Gao, W. Gu, F. Zhao, X. Feng, and H. Yan, “An intelligent diagnosis method of brain mri tumor segmentation using deep convolutional neural network and svm algorithm,” *Computational and Mathematical Methods in Medicine*, vol. 2020, pp. 1–10, 07 2020.
- [5] M. L. U. R. Shahid, T. Chitiboi, T. Ivanovska, V. Molchanov, H. Völzke, and L. Linsen, “Automatic MRI segmentation of para-pharyngeal fat pads using interactive visual feature space analysis for classification,” *BMC Medical Imaging*, vol. 17, no. 1, p. 15, Feb. 2017. [Online]. Available: <https://doi.org/10.1186/s12880-017-0179-7>
- [6] “La OMS revela las principales causas de muerte y discapacidad en el mundo: 2000-2019.” [Online]. Available: <https://www.who.int/es/news/item/09-12-2020-who-reveals-leading-causes-of-death-and-disability-worldwide-2000-2019>
- [7] J. A. González-Pliego, D. Hernández-Gordillo, E. Castañeda-Barragán, L. García-Lamas, and C. M. Guzmán-Sánchez, “Apnea obstructiva del sueño y cardiopatía isquémica. Las evidencias de su relación,” *Archivos de Cardiología de México*, vol. 85, no. 1, pp. 16–22, Jan.

- 2015, publisher: Elsevier. [Online]. Available: <https://www.elsevier.es/es-revista-archivos-cardiologia-mexico-293-articulo-apnea-obstructiva-del-sueno-cardiopatia-S14059>
- [8] F. Villar Álvarez, M. Méndez Bailón, and J. de Miguel Díez, “Enfermedad pulmonar obstructiva crónica e insuficiencia cardíaca,” *Archivos de Bronconeumología*, vol. 45, no. 8, pp. 387–393, Aug. 2009. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0300289609001884>
- [9] “La apnea del sueño aumenta el riesgo de cardiopatía - Fundación Española del Corazón.” [Online]. Available: <https://fundaciondelcorazon.com/prensa/notas-de-prensa/2435-apnea-del-sueno-aumenta-riesgo-cardiopatia.html>
- [10] G. Jean-Louis, F. Zizi, L. T. Clark, C. D. Brown, and S. I. McFarlane, “Obstructive Sleep Apnea and Cardiovascular Disease: Role of the Metabolic Syndrome and Its Components,” *Journal of Clinical Sleep Medicine : JCSM : official publication of the American Academy of Sleep Medicine*, vol. 4, no. 3, pp. 261–272, Jun. 2008. [Online]. Available: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC2546461/>
- [11] A. Barón and S. Paez-Moya, “Repercusiones cardiovasculares del síndrome de apnea-hipopnea obstructiva del sueño (SAHOS),” *Revista de la Facultad de Medicina*, vol. 65, no. 1Sup, pp. 39–46, Aug. 2017. [Online]. Available: <http://revistas.unal.edu.co/index.php/revfacmed/article/view/59666>
- [12] D. Ingram, T. Lee-Chiong, and D. Londoño, “Costos e impacto económico del síndrome de apnea-hipopnea obstructiva del sueño (SAHOS) para la salud pública,” *Revista de la Facultad de Medicina*, vol. 65, no. 1Sup, pp. 141–147, Aug. 2017. [Online]. Available: <http://revistas.unal.edu.co/index.php/revfacmed/article/view/59570>
- [13] R. Henry Olivi, “Apnea del sueño: cuadro clínico y estudio diagnóstico,” *Revista Médica Clínica Las Condes*, vol. 24, no. 3, pp. 359–373, May 2013. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0716864013701731>
- [14] “Estudio del Sueño en Madrid Hospital Viamed Santa Elena al precio de 499€ | ClinicPoint.” [Online]. Available: <https://www.clinicpoint.com/madrid/offer/6148/estudio-del-sueno-con-ingreso-hospitalario>
- [15] “Cuanto cuesta un estudio de polisomnografia?” [Online]. Available: <https://www.doctoralia.com.mx/preguntas-respuestas/cuanto-cuesta-un-estudio-de-polisomnografia>

- [16] "How Much Does the Average Sleep Study Cost?" [Online]. Available: <https://www.goodrx.com/health-topic/procedures/how-much-sleep-study-cost>
- [17] "Clinical Practice Guideline for Diagnostic Testing for Adult Obstructive Sleep Apnea: An American Academy of Sleep Medicine Clinical Practice Guideline." [Online]. Available: <https://jcsm.aasm.org/doi/epdf/10.5664/jcsm.6506>
- [18] N. Sharma and L. M. Aggarwal, "Automated medical image segmentation techniques," *Journal of Medical Physics / Association of Medical Physicists of India*, vol. 35, no. 1, pp. 3–14, 2010. [Online]. Available: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC2825001/>
- [19] H.-C. Chen, C.-J. Wang, Y.-L. Lo, H.-C. Hsu, C.-G. Huang, I.-C. Kuo, Y.-A. Lu, L.-J. Hsin, W.-N. Lin, T.-J. Fang, H.-Y. Li, and L.-A. Lee, "Parapharyngeal fat pad area at the subglosso-supraglottic level is associated with corresponding lateral wall collapse and apnea-hypopnea index in patients with obstructive sleep apnea: a pilot study," *Scientific Reports*, vol. 9, no. 1, p. 17722, Nov. 2019, number: 1 Publisher: Nature Publishing Group. [Online]. Available: <https://www.nature.com/articles/s41598-019-53515-5>
- [20] P. Mayer, J. Pepin, G. Bettega, D. Veale, G. Ferretti, C. Deschaux, and P. Levy, "Relationship between body mass index, age and upper airway measurements in snorers and sleep apnoea patients," *European Respiratory Journal*, vol. 9, no. 9, pp. 1801–1809, Sep. 1996. [Online]. Available: <http://erj.ersjournals.com/lookup/doi/10.1183/09031936.96.09091801>
- [21] R. Pahkala, J. Seppä, A. Ikonen, G. Smirnov, and H. Tuomilehto, "The impact of pharyngeal fat tissue on the pathogenesis of obstructive sleep apnea," *Sleep and Breathing*, vol. 18, no. 2, pp. 275–282, May 2014. [Online]. Available: <https://doi.org/10.1007/s11325-013-0878-4>
- [22] A. Oliven, E. Kaufman, R. Kaynan, R. Oliven, U. Steinfeld, N. Tov, M. Odeh, L. Gaitini, A. R. Schwartz, and E. Kimmel, "Mechanical parameters determining pharyngeal collapsibility in patients with sleep apnea," *Journal of Applied Physiology*, vol. 109, no. 4, pp. 1037–1044, 2010, eprint: <https://doi.org/10.1152/japplphysiol.00019.2010>. [Online]. Available: <https://doi.org/10.1152/japplphysiol.00019.2010>
- [23] T. Kline, P. Korfiatis, M. Edwards, J. Blais, F. Czerwiec, P. Harris, B. King, V. Torres, and B. Erickson, "Performance of an artificial multi-observer deep neural network

- for fully automated segmentation of polycystic kidneys,” *Journal of digital imaging*, vol. 30, 05 2017.
- [24] F. Milletari, N. Navab, and S.-A. Ahmadi, “V-net: Fully convolutional neural networks for volumetric medical image segmentation,” 10 2016, pp. 565–571.
- [25] Y. Wang, L. Zhao, M. Wang, and Z. Song, “Organ at risk segmentation in head and neck ct images using a two-stage segmentation framework based on 3d u-net,” *IEEE Access*, vol. 7, pp. 144 591–144 602, 2019.
- [26] M. Venegas-Mariño and A. Franco-Vélez, “Métodos diagnósticos en el síndrome de apnea-hipopnea obstructiva del sueño (sahos) diagnostic methods in obstructive sleep apnea-hypopnea syndrome (osahs),” *Rev. Fac. Med*, vol. 65, pp. 91–96, 5 2017. [Online]. Available: <http://dx.doi.org/10.15446/revfacmed.v65n1Sup.59643>
- [27] S. Y. Chae, S. Suh, I. Ryoo, A. Park, K. J. Noh, H. Shim, and H. Y. Seol, “A semi-automated volumetric software for segmentation and perfusion parameter quantification of brain tumors using 320-row multidetector computed tomography: a validation study,” *Neuroradiology*, vol. 59, no. 5, pp. 461–469, 2017.
- [28] H. McGrath, P. Li, R. Dorent, R. Bradford, S. Saeed, S. Bisdas, S. Ourselin, J. Shapey, and T. Vercauteren, “Manual segmentation versus semi-automated segmentation for quantifying vestibular schwannoma volume on mri,” *International journal of computer assisted radiology and surgery*, vol. 15, no. 9, pp. 1445–1455, 2020.
- [29] G. Wang, W. Li, M. A. Zuluaga, R. Pratt, P. A. Patel, M. Aertsen, T. Doel, A. L. David, J. Deprest, S. Ourselin *et al.*, “Interactive medical image segmentation using deep learning with image-specific fine tuning,” *IEEE transactions on medical imaging*, vol. 37, no. 7, pp. 1562–1573, 2018.
- [30] K. Tingelhoff, A. I. Moral, M. E. Kunkel, M. Rilk, I. Wagner, K. W. G. Eichhorn, F. M. Wahl, and F. Bootz, “Comparison between manual and semi-automatic segmentation of nasal cavity and paranasal sinuses from ct images,” in *2007 29th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, 2007, pp. 5505–5508.
- [31] 14:00-17:00, “ISO/IEC 25010:2011.” [Online]. Available: <https://www.iso.org/cms/render/live/en/sites/isoorg/contents/data/standard/03/57/35733.html>
- [32] R. Wojcik, F. Bachmann, L. Bass, P. Clements, P. Merson, R. Nord, and B. Wood, “Attribute-Driven Design (ADD), Version 2.0;,” Defense Technical

- Information Center, Fort Belvoir, VA, Tech. Rep., Nov. 2006. [Online]. Available: <http://www.dtic.mil/docs/citations/ADA460414>
- [33] R. Gonzalez and A. Pomares Quimbaya, *La investigación científica basada en el diseño como eje de proyectos de investigación en ingeniería*, Sep. 2012.
- [34] J. Sutherland, *Jeff Sutherland's Scrum Handbook*, Jan. 2010.
- [35] J. Jones, “Parapharyngeal space | Radiology Reference Article | Radiopaedia.org.” [Online]. Available: <https://radiopaedia.org/articles/parapharyngeal-space>
- [36] H. E. Stambuk and S. G. Patel, “Imaging of the Parapharyngeal Space,” *Otolaryngologic Clinics of North America*, vol. 41, no. 1, pp. 77–101, Feb. 2008. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0030666507001995>
- [37] K. J. Parejo-Gallardo, “Definición del síndrome de apnea-hipopnea obstructiva del sueño (SAHOS),” *Revista de la Facultad de Medicina*, vol. 65, no. 1Sup, pp. 9–10, Aug. 2017. [Online]. Available: <http://revistas.unal.edu.co/index.php/revfacmed/article/view/59718>
- [38] V. M. Eguía and J. A. Cascante, “Síndrome de apnea-hipopnea del sueño: Concepto, diagnóstico y tratamiento médico,” *Anales del Sistema Sanitario de Navarra*, vol. 30, pp. 53–74, 2007, publisher: Gobierno de Navarra. Departamento de Salud. [Online]. Available: https://scielo.isciii.es/scielo.php?script=sci_abstract&pid=S1137-66272007000200005&lng=es&nrm=iso&tlang=es
- [39] “Ct scan vs. mri: What’s the difference? and how do doctors choose which imaging method to use? — memorial sloan kettering cancer center,” <https://www.mskcc.org/news/ct-vs-mri-what-s-difference-and-how-do-doctors-choose-which-imaging-method-use#:~:text=CT%20scans%20take%20a%20fast,a%20CT%20scan%20cannot%20detect.,> (Accessed on 11/15/2022).
- [40] T. Ivanovska, E. Buttke, R. Laqua, H. Völzke, and A. Beule, “Automatic trachea segmentation and evaluation from mri data using intensity pre-clustering and graph cuts,” in *2011 7th International Symposium on Image and Signal Processing and Analysis (ISPA)*, 2011, pp. 513–518.
- [41] “Riesgo de radiación de las imágenes médicas - harvard health,” <https://www.health.harvard.edu/cancer/radiation-risk-from-medical-imaging>, (Accessed on 11/15/2022).

- [42] RadiologyInfo, “Dosis de radiación en los exámenes por rayos x y tc,” <https://www.radiologyinfo.org/es/info/safety-xray>, 2022, (Accessed on 11/15/2022).
- [43] Welte, “Imaging in the diagnosis of lung disease - pmc,” <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC3977440/>, 03 2014, (Accessed on 11/14/2022).
- [44] H. Hatabu, Y. Ohno, W. B. Gefter, G. Parraga, B. Madore, K. S. Lee, T. A. Altes, D. A. Lynch, J. R. Mayo, J. B. Seo, J. M. Wild, E. J. R. van Beek, M. L. Schiebler, and H.-U. a. Kauczor, “Expanding applications of pulmonary mri in the clinical evaluation of lung disorders: Fleischner society position paper,” *Radiology*, vol. 297, no. 2, pp. 286–301, 2020, pMID: 32870136. [Online]. Available: <https://doi.org/10.1148/radiol.2020201138>
- [45] P. Aggarwal, R. Vig, S. Bhadaria, and A. C.G.Dethe, “Role of segmentation in medical imaging: A comparative study,” *International Journal of Computer Applications*, vol. 29, 2011.
- [46] A. S. Ashour, Y. Guo, and W. S. Mohamed, “9 - image-guided thermal ablation therapy,” in *Thermal Ablation Therapy*, A. S. Ashour, Y. Guo, and W. S. Mohamed, Eds. Academic Press, 2021, pp. 411–440. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/B9780128195444000101>
- [47] A. A. Taha and A. Hanbury, “Metrics for evaluating 3d medical image segmentation: Analysis, selection, and tool,” *BMC Medical Imaging*, vol. 15, 2015.
- [48] B. AI, “Redes neuronales convolucionales,” Nov. 2019. [Online]. Available: <https://bootcampai.medium.com/redes-neuronales-convolucionales-5e0ce960caf8>
- [49] S. Minaee, Y. Boykov, F. Porikli, A. Plaza, N. Kehtarnavaz, and D. Terzopoulos, “Image Segmentation Using Deep Learning: A Survey,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 7, pp. 3523–3542, Jul. 2022, conference Name: IEEE Transactions on Pattern Analysis and Machine Intelligence.
- [50] R. Chauhan, K. K. Ghanshala, and R. Joshi, “Convolutional Neural Network (CNN) for Image Detection and Recognition,” in *2018 First International Conference on Secure Cyber Computing and Communication (ICSCCC)*, Dec. 2018, pp. 278–282.
- [51] M. H. Hesamian, W. Jia, X. He, and P. Kennedy, “Deep Learning Techniques for Medical Image Segmentation: Achievements and Challenges,” *Journal of Digital Imaging*, vol. 32, no. 4, pp. 582–596, Aug. 2019. [Online]. Available: <https://doi.org/10.1007/s10278-019-00227-x>

- [52] G. Singh, “LSTM Architecture | Understanding the LSTM Architecture,” Jan. 2021. [Online]. Available: <https://www.analyticsvidhya.com/blog/2021/01/understanding-architecture-of-lstm/>
- [53] “Rethinking dice loss for medical image segmentation — ieee conference publication — ieee xplore,” <https://ieeexplore.ieee.org/document/9338261>, (Accessed on 11/11/2022).
- [54] “Brats2020 dataset (training + validation) — kaggle,” <https://www.kaggle.com/datasets/awsaf49/brats20-dataset-training-validation>, (Accessed on 11/11/2022).
- [55] “focal_loss.sparsecategoricalfocalloss — focal-loss 0.0.8 documentation,” https://focal-loss.readthedocs.io/en/latest/generated/focal_loss.SparseCategoricalFocalLoss.html, (Accessed on 11/11/2022).
- [56] A. Pareek, “Staff and their responsibilities in radiology center cancer therapy & oncology international journal,” *Canc Therapy & Oncol Int J*, vol. 10, p. 1, 5 2018. [Online]. Available: <https://juniperpublishers.com/online-submission.php>
- [57] K. Tingelhoff, A. I. Moral, M. E. Kunkel, M. Rilk, I. Wagner, K. W. Eichhorn, F. M. Wahl, and F. Bootz, “Comparison between manual and semi-automatic segmentation of nasal cavity and paranasal sinuses from ct images,” *Annual International Conference of the IEEE Engineering in Medicine and Biology Society. IEEE Engineering in Medicine and Biology Society. Annual International Conference*, vol. 2007, pp. 5505–5508, 2007. [Online]. Available: <https://pubmed.ncbi.nlm.nih.gov/18003258/>
- [58] D. Müller and F. Kramer, “Miscnn: a framework for medical image segmentation with convolutional neural networks and deep learning,” *BMC Medical Imaging*, vol. 21, 12 2021.
- [59] M. P. Starmans, S. R. der Voort, J. M. Tovar, J. F. Veenland, S. Klein, and W. J. Niessen, “Radiomics: Data mining using quantitative medical image features,” *Handbook of Medical Image Computing and Computer Assisted Intervention*, pp. 429–456, 1 2020.

Apendices

Los siguientes anexos de esta memoria se encuentran en el siguiente repositorio:

https://github.com/debruit/trabajo_grado

- Anexo 1. Plan de proyecto
- Anexo 2. Especificación de requisitos (SRS)
- Anexo 3. Documento de arquitectura de software (SAD)
- Anexo 4. Plan de pruebas
- Anexo 5. Documentos de pruebas.
- Anexo 6. Código fuente
- Anexo 7. Diseño de la arquitectura (ADD)
- Anexo 8. Propuesta de trabajo de grado (VFP)